Aprendizaje automático y control avanzado para la regulación del pH en la industria azucarera: una revisión de alcance y análisis bibliométrico

Machine Learning and Advanced Control for pH Regulation in the Sugar Industry: A Scoping Review and Bibliometric Analysis

Abraham Castillo[a,*] **D. Barreto**[a]

[a]Escuela de Posgrado, Universidad Nacional de Ingeniería, Av. Túpac Amaru 210, Lima 15333, Perú

[*]*Autor de correspondencia:* abraham.castillo.a@uni.pe

Recibido: *Revisado:* *Aceptado:* *Publicado en línea:*

Declaración de financiamiento. Esta investigación no recibió financiamiento específico de agencias públicas, del sector comercial ni de organismos sin fines de lucro.

Declaración de conflictos de interés. Los autores declaran que no existe ningún conflicto de interés conocido que haya podido influir en los resultados reportados en este artículo.

Disponibilidad de datos y código. El protocolo, las cadenas booleanas por base (incluyendo SciELO y LILACS), los registros de decisiones de cribado (humanas y automáticas), la matriz de co-ocurrencia de palabras clave, la matriz de confusión inter-humano, los resultados de los análisis de sensibilidad y el código del *pipeline* (cribado, verificación léxica y chequeo con modelo de lenguaje, con el *prompt* y el resumen SHA-256 del modelo) están disponibles en el Open Science Framework (**[osf.io/. . .]**) y en GitHub (github.com/acastillo1975/rsl-ph-azucarera).

Registro del protocolo. El protocolo de la revisión de alcance se registró en OSF de forma **retrospectiva**, el **[fecha de registro OSF]**, es decir, después de ejecutar la búsqueda (22 de junio de 2026) y de un cribado preliminar; por tanto, el registro documenta el diseño pero no constituye una preespecificación independiente. Se elaboró siguiendo la extensión PRISMA-ScR (Tricco et al., 2018) y el marco metodológico para revisiones de alcance (Arksey & O'Malley, 2005; Munn et al., 2018): **[osf.io/. . .]**. Las desviaciones respecto del diseño inicial se declaran en la sección 2.1.

Aprobación ética. Esta investigación es una revisión de literatura publicada y no involucra participantes humanos ni animales; por tanto, no requiere aprobación de comité de ética.

Resumen

El pH del jugo alcalinizado es la variable crítica del encalado azucarero, y la ganancia variable de su curva de titulación degrada el control PID convencional. El aprendizaje automático (AA) y el control avanzado se han desarrollado en otros procesos de neutralización, pero su evidencia en el proceso azucarero no estaba cartografiada. Se realizó una revisión de alcance (PRISMA-ScR) en cinco bases (Scopus, WoS, IEEE Xplore, SciELO, LILACS; 2015–2026) con criterios explícitos: artículos de revista con cuartil SJR que aplicaran AA, control avanzado o sensores virtuales al pH de la clarificación. El cribado fue doble, ciego e independiente de los 230 registros por dos revisores, con κ inter-humano como métrica primaria (κ =1.000). De 541 registros iniciales, dos estudios cumplieron todos los criterios: un NMPC con identificación Takagi–Sugeno y la sintonía metaheurística de un PID identificado con datos de planta; ambos validaron el control solo en simulación. Un análisis de sensibilidad halló otros 11 trabajos *in-domain* excluidos por criterios formales (3 artículos en revistas sin cuartil y 8 actas), también basados en simulación. Ninguno de los 13 aplicó aprendizaje por refuerzo ni propone un sensor virtual de pH en línea, ninguno declara control en lazo cerrado en planta industrial y 10 provienen de dos grupos de autores. La brecha es de madurez y diversidad metodológica, no de ausencia de investigación. Se propone una agenda por horizontes: control neuro-difuso y sensores virtuales, NMPC de caja gris y aprendizaje por refuerzo con validación en planta.

Palabras clave: control de pH; industria azucarera; aprendizaje automático; control predictivo; revisión de alcance; análisis bibliométrico; brecha de investigación

Abstract

The pH of alkalinized juice is the critical variable of sugar-industry liming, and the variable gain of its titration curve degrades conventional PID control. Machine learning (ML) and advanced control have been developed for other neutralization processes, but their evidence in the sugar process had not been mapped. A scoping review (PRISMA-ScR) was conducted in Scopus, Web of Science, IEEE Xplore, SciELO and LILACS (2015–2026) with explicit criteria: journal articles with an SJR quartile (Q1–Q4) applying ML, advanced control or virtual sensors to clarification or liming pH. Screening was double, blinded and independent, by two reviewers on all 230 records, with inter-rater κ as the primary metric (κ =1.000). Of 541 initial records, two studies met all criteria: an NMPC with Takagi–Sugeno identification, and metaheuristic PID tuning with identification from plant data; control was validated only in simulation. A sensitivity analysis found 11 further in-domain works excluded by formal criteria (3 articles in journals without a quartile and 8 conference papers or chapters), also simulation-based. None of the 13 applied reinforcement learning or proposes a virtual pH sensor for online use, and none reports closed-loop control in an industrial plant; 10 come from two author groups. The gap concerns maturity and methodological diversity, not an absence of research. A horizon-based agenda is proposed: neuro-fuzzy control and virtual sensors, grey-box NMPC, and reinforcement learning with plant validation.

Keywords: pH control; sugar industry; machine learning; predictive control; scoping review; bibliometric analysis; research gap

1 Introducción

1.1 Contexto industrial: el pH en la clarificación azucarera

La caña de azúcar aporta la mayor parte de la sacarosa comercializada en el mundo (Rein, 2007). Dentro de la cadena de fabricación —preparación de caña, extracción, *clarificación y encalado*, evaporación, cristalización, centrifugación y secado—, la clarificación es la primera operación de purificación del jugo crudo y la más sensible al control de pH. La adición controlada de lechada de cal (*liming*) eleva el pH desde su valor natural ácido ($\approx$ 4.8–5.8) hasta el rango objetivo de alcalinización ($\approx$ 7.0–7.2), lo que precipita coloides, ceras, materia colorante y sales inorgánicas y protege la sacarosa de la hidrólisis ácida (Rein, 2007).

Las desviaciones del *setpoint* tienen consecuencias económicas en ambos sentidos. Si el pH desciende por debajo de $\approx$ 6.8, la acidez residual cataliza la inversión de sacarosa en glucosa y fructosa y reduce el rendimiento azucarero; si excede $\approx$ 7.4, el exceso de cal favorece la formación de sacaratos de calcio y compuestos coloreados que afectan la calidad del azúcar y la eficiencia de los evaporadores (Rein, 2007; Shinskey, 1996). Por ello el encalado se reconoce como una operación cuya regulación tiene retorno directo sobre la rentabilidad del ingenio.

1.2 El problema de control del pH: ganancia variable y no linealidad

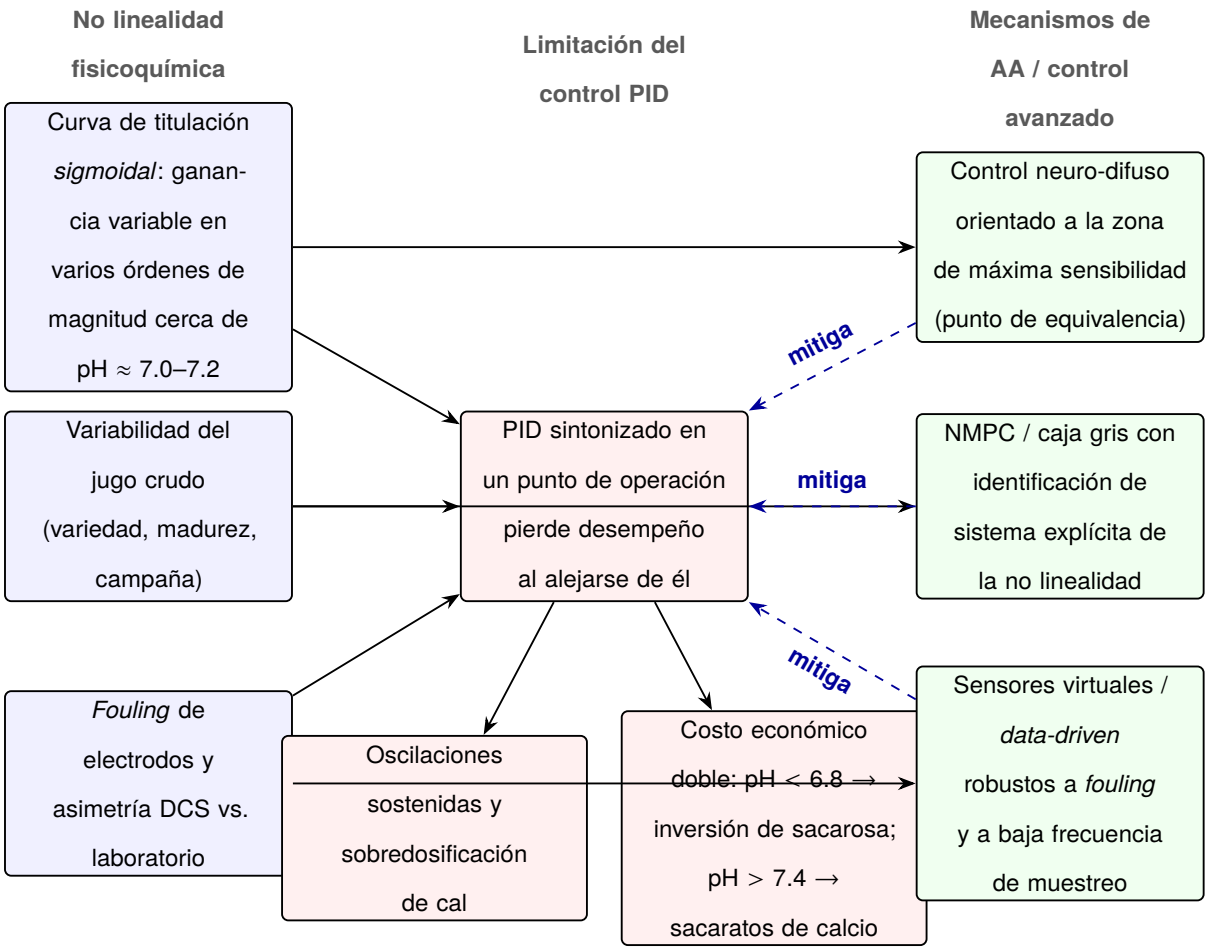
El encalado es una instancia del problema clásico de neutralización ácido–base: la curva de titulación es fuertemente sigmoidal, con una ganancia estática que varía en varios órdenes de magnitud alrededor del punto de equivalencia (Shinskey, 1996), comportamiento que se formaliza con los invariantes de reacción de Gustafsson y Waller (1983). Un controlador PID sintonizado en un punto de operación pierde desempeño al alejarse de él, con oscilaciones y sobredosificación de reactivo. A esa no linealidad se superponen tres dificultades atribuidas en la literatura tecnológica al jugo de caña (García et al., 1989; Rein, 2007): (i) **variabilidad temporal** del jugo crudo, cuya composición ácida depende de la variedad, la madurez y la campaña; (ii) **asimetría de instrumentación**, con mediciones DCS a resolución de minutos y análisis de laboratorio cada 1–2 horas; y (iii) **ensuciamiento** (*fouling*) de los electrodos por depósitos de cal, que introduce derivas y exige recalibración frecuente. La Figura 1 resume esta cadena causal, de

la no linealidad fisicoquímica a las limitaciones del PID, y los mecanismos mediante los cuales el aprendizaje automático (AA) y el control avanzado, discutidos en 1.3 y 4.2, podrían mitigarlas.

Conviene precisar el alcance de esta premisa: que el PID se degrada en el encalado es una consecuencia prevista por la teoría de control de pH y reportada de forma cualitativa por los propios estudios del dominio (Murugesan et al., 2020); no se localizó, en las fuentes revisadas, un estudio que cuantifique el desempeño de lazos PID en clarificadores industriales (error de pH, consumo de cal, pérdidas de sacarosa). Esa ausencia de línea base empírica es, en sí misma, parte del problema que esta revisión documenta.

Figura 1

Esquema causal propio: de la no linealidad fisicoquímica del encalado a las limitaciones del control PID, y mecanismos por los cuales el aprendizaje automático y el control avanzado podrían mitigarlas.



Nota. Elaboración propia. Las flechas sólidas representan relaciones causales introducidas en los párrafos anteriores y desarrolladas con su respaldo bibliográfico en 1.3; las flechas discontinuas señalan el mecanismo de mitigación propuesto por cada familia de métodos, desarrollado en 4.2 y en la agenda de investigación (4.3). El esquema es conceptual y no representa un diagrama de bloques de control formal.

1.3 Avances en AA y control avanzado en otros dominios

Fuera de la industria azucarera, la dificultad del control de pH ha motivado cuatro décadas de desarrollo metodológico. Los trabajos fundacionales formularon el control adaptativo no lineal basado en invariantes de reacción (Henson & Seborg, 1994), el control predictivo con identificación no lineal en tiempo real (Pröll & Nazmul Karim, 1994) y las redes neuronales para capturar la relación entrada–pH sin un modelo mecanístico explícito (Palancar et al., 1998); en

paralelo se propusieron esquemas proporcional-integrales avanzados con inyección dual para mitigar la ganancia variable (Hurowitz et al., 2000).

Sobre esa base se ha consolidado un repertorio diverso. El control predictivo lineal y no lineal se ha aplicado a la regulación de pH en bioprocesos y fotobiorreactores (Berenguel et al., 2004; Otálora et al., 2026) y, más recientemente, se ha combinado con identificación por aprendizaje profundo para sintetizar controladores del proceso de neutralización (Durairaj et al., 2023). Los enfoques difusos y neuro-difusos han resultado adecuados para operar cerca del punto de equivalencia, donde la sensibilidad del proceso es máxima (Heredia-Molinero et al., 2014; Suguna et al., 2026). En la frontera actual, el aprendizaje por refuerzo ha permitido diseñar políticas autónomas para la neutralización de efluentes de galvanoplastia y para procesos multivariables de pH (Alves Goulart & Dutra Pereira, 2020; Panjapornpon et al., 2022), y los enfoques *data-driven* y de sensores virtuales han abordado la predicción de pH y la dosificación de reactivos cuando la instrumentación física es limitada o poco fiable (Bardeeniz et al., 2025; Son et al., 2021; Xu et al., 2022).

Este cuerpo de conocimiento abarca el tratamiento de aguas residuales, los fotobiorreactores, la desalación y la galvanoplastia, y su madurez se apoya sobre todo en formulación y validación en simulación, con implementaciones experimentales en algunos casos. Cabe preguntarse en qué medida estos avances han llegado al proceso de clarificación del jugo de caña, cuya dinámica de pH es análoga pero presenta particularidades —composición coloidal, multiplicidad de ácidos débiles, estacionalidad y *fouling*— que podrían condicionar la transferencia.

1.4 Brecha de investigación y justificación del enfoque

Una búsqueda exploratoria sobre Scopus, Web of Science e IEEE Xplore sugería que la evidencia *intra-dominio* (*in-domain*) sobre AA y control avanzado aplicados específicamente al pH del proceso azucarero era escasa y no existía un mapeo sistemático de su extensión y naturaleza. Ese contexto —tema acotado, evidencia dispersa en tipos de documento heterogéneos y objetivo de cartografiar más que de sintetizar efectos— corresponde a una **revisión de alcance** (Arksey & O'Malley, 2005; Levac et al., 2010; Peters et al., 2020). Se adoptó un protocolo sistemático, y no una revisión narrativa, porque solo una estrategia de búsqueda reproducible y

un embudo de decisiones auditable permiten distinguir entre "no hay evidencia" y "no se buscó exhaustivamente", distinción central cuando el corpus elegible es pequeño (Lang et al., 2007; Yaffe et al., 2012). La justificación completa del diseño se presenta en 2.1; la síntesis narrativa de la evidencia transferible, en 4.2.

1.5 Objetivo y preguntas de investigación

El **objetivo** es cartografiar la extensión, la naturaleza y el nivel de madurez de la evidencia sobre AA, control avanzado y sensores virtuales aplicados a la regulación del pH en la clarificación y el encalado del jugo azucarero, e identificar vacíos que orienten una agenda de investigación. Bajo un marco PICOC adaptado (*Population*: procesos de clarificación y encalado de jugo de caña o remolacha; *Intervention*: técnicas de AA, control avanzado o sensores virtuales; *Comparison*: PID, dosificación manual o lazo abierto; *Outcomes*: desempeño del control de pH y evidencia de modelado; *Context*: revistas indexadas en SJR, cualquier cuartil, 2015–2026) se formulan tres preguntas con correspondencia biunívoca con las consultas de búsqueda:

RQ1 ¿Cómo se ha modelado y estimado la dinámica del pH en la clarificación azucarera mediante sensores virtuales, identificación de sistemas y modelos *data-driven*?

RQ2 ¿Qué estrategias de control avanzado (MPC/NMPC, lógica difusa, metaheurísticas) se han aplicado al lazo de pH y cómo se comparan con el control PID convencional?

RQ3 ¿Qué técnicas de aprendizaje automático, aprendizaje por refuerzo y modelos híbridos se han empleado, y qué barreras limitan su adopción industrial?

Contribución. Hasta donde alcanza el conocimiento de los autores, este es el primer mapeo sistemático, reportado bajo PRISMA-ScR, de la intersección {AA/control avanzado $\times$ pH $\times$ industria azucarera}. Aporta: *(i)* un corpus auditado registro a registro, con fiabilidad de cribado cuantificada y análisis de sensibilidad de los criterios de elegibilidad; *(ii)* la caracterización del campo adyacente mediante bibliometría y una verificación léxica independiente; y *(iii)* una agenda priorizada por transferibilidad técnica y nivel de madurez, orientada a cerrar la distancia entre simulación y validación en planta.

2 Materiales y métodos

2.1 Diseño del estudio, protocolo y guía de reporte

Se realizó una **revisión de alcance** con un componente bibliométrico explícito, siguiendo el marco de Arksey y O'Malley (Arksey & O'Malley, 2005) con las mejoras de Levac et al. (Levac et al., 2010), las precisiones de Munn et al. (Munn et al., 2018) y la guía del *Joanna Briggs Institute* (Peters et al., 2020). Se reportó conforme a PRISMA-ScR (Tricco et al., 2018) (lista de verificación en el Apéndice E); el diagrama de flujo sigue la convención de PRISMA 2020 (Page et al., 2021). El protocolo se registró en OSF (**[osf.io/. . .]**) el **[fecha de registro OSF]**, **de forma retrospectiva**: después de ejecutar la búsqueda (22 de junio de 2026) y de un cribado preliminar. El registro documenta el diseño, los criterios y las consultas tal como se aplicaron, pero no constituye una preespecificación independiente, de modo que el riesgo de sesgo de reporte selectivo no puede descartarse por esa vía; se mitiga publicando las cadenas de búsqueda, los registros de decisiones y el código (GitHub), con su historial de cambios.

Desviaciones respecto del diseño inicial.. Dos criterios de elegibilidad se modificaron respecto del diseño inicial y antes del cribado sobre el corpus definitivo: (i) el umbral de cuartil SJR se amplió de Q1–Q2 a Q1–Q4 el 13 de agosto de 2026, al comprobar que la búsqueda no había restringido por cuartil y que, en un dominio de nicho, un umbral alto podía descartar evidencia *in-domain*; y (ii) la ventana temporal se extendió hasta 2026 para incorporar publicaciones *early access*. La primera enmienda fue posterior a un cribado preliminar sobre Q1–Q2 que había identificado un único estudio, es decir, se tomó con conocimiento parcial de los resultados; se declara como fuente potencial de sesgo y se acota con el análisis de sensibilidad de 2.8.

Justificación del diseño.. Se descartó una revisión narrativa y una revisión sistemática agnóstica del dominio por tres razones. Primero, la pregunta es de mapeo (extensión, naturaleza y madurez de la evidencia), no de efectividad, por lo que no procede un metaanálisis. Segundo, el tamaño reducido del corpus es un resultado a sostener, y solo una estrategia de búsqueda reproducible con un embudo de decisiones auditable distingue "no hay evidencia" de "no se buscó exhaustivamente" (Lang et al., 2007; Yaffe et al., 2012); la literatura transferible de otros dominios se sintetiza de

forma narrativa en 4.2, de modo que el diseño combina ambos enfoques. Tercero, el componente bibliométrico caracteriza el campo adyacente para interpretar el vacío. Una revisión agnóstica (control de pH con AA en cualquier industria) habría respondido otra pregunta y solaparía revisiones existentes sobre bioprocesos y efluentes.

2.2 Criterios de elegibilidad

Los criterios se definieron bajo el marco PICOC descrito en 1.5.

Inclusión. (a) Artículos de revista originales publicados entre 2015 y 2026, incluyendo registros *early access* con año editorial 2026; (b) revista indexada en SJR (SCImago, edición 2024, criterio *best quartile*) con cuartil Q1–Q4; (c) aplicación de al menos una técnica de AA, de control avanzado o de sensor virtual al pH del proceso de clarificación o encalado del jugo de caña o remolacha; se consideró *control avanzado* todo esquema distinto de un PID de ganancia fija (MPC/NMPC, control difuso o neuro-difuso, adaptativo) y se admitió la identificación o sintonía de controladores mediante metaheurísticas o AA; y (d) reporte de al menos una métrica cuantitativa de desempeño.

Exclusión. (a) Actas de congreso, capítulos y series de libros; (b) fuera del rango temporal; (c) revista sin cuartil SJR en SCImago 2024; (d) procesos ajenos al lazo de pH de la clarificación azucarera (fermentación alcohólica, tratamiento de aguas residuales, jugos de fruta, farmacéutica, extracción mineral, análisis sensorial); y (e) pH tratado solo como descriptor químico o variable de entrada, sin objetivo de predicción, estimación o control.

Justificación y riesgos de los criterios formales. Restringir a artículos de revista con cuartil SJR persigue una calidad editorial verificable y homogénea; el rango completo Q1–Q4 evita sesgar *a priori* un dominio de nicho hacia los cuartiles superiores. Sin embargo, estos criterios tienen un costo: excluyen la literatura de ingeniería publicada en actas y las revistas no indexadas en SCImago, que en control de procesos pueden concentrar parte de la evidencia. Por esa razón se planteó una caracterización de los registros *in-domain* excluidos por estos criterios (2.8); los resultados se reportan por separado de los estudios que cumplen todos los criterios.

Ventana temporal. La ventana 2015–2026 abarca la difusión del aprendizaje profundo y del aprendizaje por refuerzo profundo en ingeniería (Krizhevsky et al., 2012; Mnih et al., 2015) y la

literatura reciente sobre NMPC con identificación no lineal. Un *cutoff* anterior habría incorporado trabajos fundacionales que, siendo relevantes como contexto (1.3), no reflejan el estado actual del campo.

2.3 Fuentes de información y estrategia de búsqueda

Se consultaron **cinco bases de datos** el 22 de junio de 2026: Scopus, Web of Science e IEEE Xplore, más **SciELO** y **LILACS** para incrementar la cobertura de literatura latinoamericana y brasileña en español y portugués, dada la relevancia del sector azucarero en Brasil. Se ejecutaron nueve consultas booleanas (tres por base original, mapeadas 1 a 1 con las tres preguntas de investigación) y una consulta combinada adicional por base para SciELO y LILACS, adaptada a su sintaxis (Tabla 1; cadenas completas en el Apéndice A). Las consultas incorporaron cláusulas `AND NOT` para excluir dominios tópicamente ruidosos detectados en una búsqueda piloto (*wastewater*, *bioethanol*, *fermentation broth*, *pharmaceutical*, *soil*, *blood*, *wine*, *dairy*, *bioreactor*).

El uso de `AND NOT` introduce un riesgo de sesgo de selección: un término de exclusión amplio puede eliminar registros *in-domain* que mencionen tangencialmente, por ejemplo, *wastewater* o *bioreactor*. Se mitigó calibrando cada término de exclusión en la búsqueda piloto sobre registros ya identificados como ruido temático y no sobre supuestos *a priori*. No se ejecutó, en cambio, una búsqueda de control sin `AND NOT` ni un rastreo sistemático de citas (*citation chasing*) sobre los estudios incluidos; por tanto, la pérdida de algún registro marginal no puede descartarse y se declara como limitación (4.4).

Tabla 1: *Consultas booleanas empleadas en la búsqueda sistemática en Scopus, Web of Science e IEEE Xplore. Correspondencia 1 a 1 con las preguntas de investigación: $Q_1 \rightarrow$ RQ1 (modelado/sensores virtuales); $Q_2 \rightarrow$ RQ2 (control avanzado vs. PID); $Q_3 \rightarrow$ RQ3 (ML/RL/híbridos y barreras). Se muestra el formato Scopus TITLE-ABS-KEY; los equivalentes semánticos por base, incluidas las cadenas específicas para SciELO y LILACS, se documentan en el Apéndice A.*

Q_i	**Foco temático (RQ)**	**Cadena booleana (Scopus TITLE-ABS-KEY)**	N
Q_1	Modelado y sensores virtuales de pH (RQ1)	`TITLE-ABS-KEY(("pH control" OR "pH monitoring" OR "pH prediction" OR "pH regulation" OR "pH measurement" OR "acidity control" OR "alkalinity control" OR "juice acidity" OR "lime dosage" OR "calcium hydroxide" OR "milk of lime") AND ("sugar mill" OR "sugarcane" OR "cane juice" OR "sugar juice" OR "sugar industry" OR "juice clarification" OR "liming process" OR "defecation" OR "sulfitation" OR "sugar beet" OR "sugar factory" OR "saccharum") AND ("soft sensor" OR "virtual sensor" OR "inferential sensor" OR "identification" OR "data-driven model" OR "neural network" OR "LSTM" OR "predictive model" OR "regression model")) AND NOT TITLE-ABS-KEY("wastewater" OR "soil pH" OR "fermentation broth" OR "bioethanol" OR "pharmaceutical" OR "bioreactor" OR "wine" OR "beer" OR "dairy")`	18
Q_2	Control avanzado (MPC/NMPC, difuso, metaheurísticas) vs. PID (RQ2)	`TITLE-ABS-KEY(("model predictive control" OR "NMPC" OR "nonlinear MPC" OR "fuzzy logic" OR "takagi-sugeno" OR "neuro-fuzzy" OR "adaptive control" OR "intelligent control" OR "PID tuning" OR "optimal control" OR "pattern search" OR "particle swarm" OR "genetic algorithm" OR "differential evolution" OR "bayesian optimization") AND "pH" AND ("sugar mill" OR "sugarcane" OR "cane juice" OR "sugar juice" OR "juice clarification" OR "liming process" OR "defecation" OR "sulfitation" OR "sugar industry" OR "sugar beet" OR "sugar factory")) AND NOT TITLE-ABS-KEY("wastewater" OR "bioethanol" OR "fermentation broth" OR "pharmaceutical" OR "soil" OR "blood" OR "wine" OR "dairy" OR "desalination" OR "anaerobic digestion" OR "bioreactor")`	60

Continued on next page

Tabla 1: *Consultas booleanas empleadas en la búsqueda sistemática en Scopus, Web of Science e IEEE Xplore. Correspondencia 1 a 1 con las preguntas de investigación: $Q_1 \rightarrow$ RQ1 (modelado/sensores virtuales); $Q_2 \rightarrow$ RQ2 (control avanzado vs. PID); $Q_3 \rightarrow$ RQ3 (ML/RL/híbridos y barreras). Se muestra el formato Scopus TITLE-ABS-KEY; los equivalentes semánticos por base, incluidas las cadenas específicas para SciELO y LILACS, se documentan en el Apéndice A.* (Continued)

Q_3	ML/RL/híbridos y barreras de adopción (RQ3)	`TITLE-ABS-KEY(("machine learning" OR "deep learning" OR "neural network" OR "artificial intelligence" OR "random forest" OR "gradient boosting" OR "XGBoost" OR "lightGBM" OR "support vector" OR "reinforcement learning" OR "deep reinforcement learning" OR "DDPG" OR "PPO" OR "Q-learning" OR "hybrid model" OR "grey-box model" OR "physics-informed" OR "digital twin" OR "transfer learning") AND "pH" AND ("sugar" OR "sugarcane" OR "cane juice" OR "sugar juice" OR "clarification" OR "liming" OR "sugar mill" OR "sugar industry" OR "sugar beet" OR "juice purification" OR "sugar factory" OR "defecation")) AND NOT TITLE-ABS-KEY("wastewater" OR "bioethanol" OR "pharmaceutical" OR "soil" OR "blood" OR "bioreactor" OR "desalination" OR "wine" OR "beer" OR "fermentation broth")`	463
Total bruto (nueve consultas, tres bases, con duplicados intra e inter-fuente)			**541**
+ Adicionales SciELO y LILACS (ver Apéndice A)			**0**

Nota. Elaboración propia. Los valores de N corresponden a las ejecuciones del 22 de junio de 2026y fueron verificados desde los archivos RIS exportados. Desglose por base original: Scopus = 312 (Q_1=11, Q_2=32, Q_3=269); WoS = 188 (Q_1=3, Q_2=18, Q_3=167); IEEE Xplore = 41 (Q_1=4, Q_2=10, Q_3=27). SciELO y LILACS se ejecutaron con consulta Q4 adaptada a DeCS/MeSH; los recuentos exactos se reportan en la Tabla A1 (Apéndice A). Sintaxis WoS: sustituir `TITLE-ABS-KEY` por `TS=` y `AND NOT` por `NOT TS=`. Sintaxis IEEE Xplore: operadores directos sobre *All Metadata* sin prefijo de campo.

2.4 Proceso de selección

Sobre el corpus bruto se aplicaron seis etapas secuenciales.

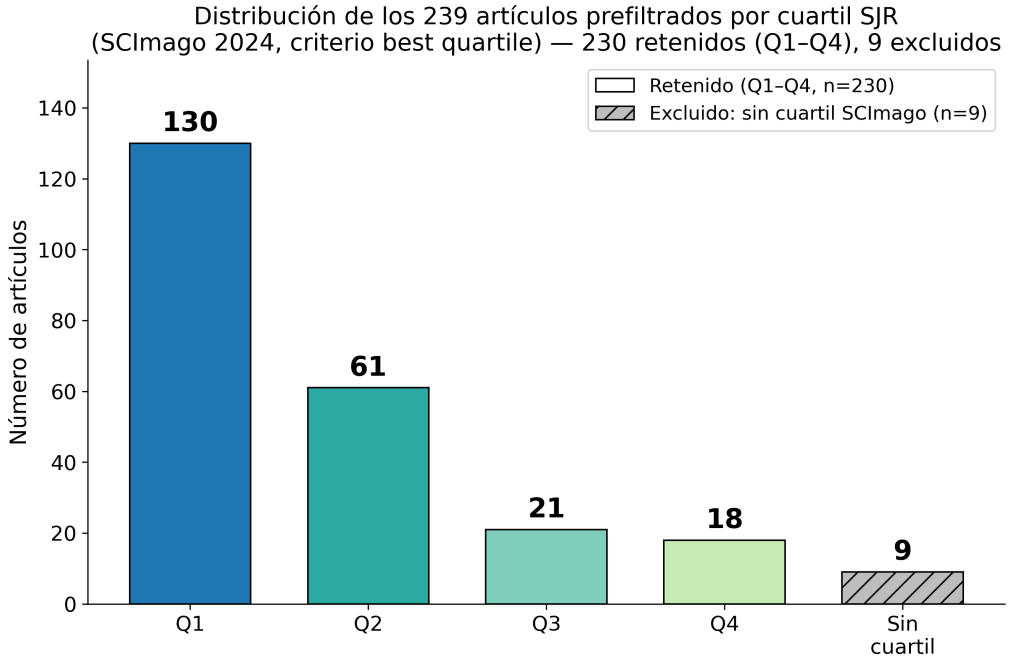
Etapa 1: Deduplicación.. Emparejamiento difuso de títulos con `rapidfuzz` (umbral 95 %) complementado por cruce por DOI: se eliminaron 188 duplicados (34.8 %), quedando 353 registros únicos.

Etapa 2: Prefiltrado por tipo y año.. Se retuvieron los artículos de revista (`TY=JOUR`), descartándose actas, capítulos y series de libros (n = 48), y se aplicó la ventana 2015–2026 (n = 66), quedando 239 registros.

Etapa 3: Anotación y filtro por cuartil SJR.. A los 239 registros se les asignó el cuartil SJR de su revista mediante cruce jerárquico con SCImago 2024: primero por ISSN (49 167 entradas) y, en su defecto, por título normalizado (30 992 entradas). Se localizaron 232 revistas (97.1 %; ISSN: 213, título: 19). La distribución fue Q1= 130 (56.5 %), Q2= 61 (26.5 %), Q3= 21 (9.1 %) y Q4= 18 (7.8 %); 9 registros (3.8 %) carecían de cuartil utilizable (7 revistas ausentes de SCImago 2024 y 2 con correspondencia pero sin cuartil asignado) y se excluyeron, quedando 230 registros (Figura 2).

Figura 2

Distribución de los 239 artículos de revista prefiltrados (2015–2026) por cuartil SJR (SCImago 2024, best quartile); los 230 registros Q1–Q4 se retuvieron y los 9 sin cuartil se excluyeron.



Nota. Elaboración propia a partir del corpus prefiltrado. La amplitud del umbral Q1–Q4 se justifica en 2.2.

Etapa 4: Doble cribado humano independiente y ciego.. Los 230 registros fueron cribados por título y resumen por **dos revisores humanos de forma independiente y ciega**. El **Revisor 1** (autor principal) y el **Revisor 2** (D. Barreto) evaluaron **el corpus completo** (n = 230) con los criterios de 2.2. Ambos revisores operaron sin acceso a las decisiones del otro ni a las del modelo de lenguaje. Las discrepancias se resolverían por consenso y, de persistir, se remitirían a un tercer revisor. La decisión consensuada es la **decisión primaria y final**; su concordancia se reporta con κ de Cohen inter-humano (2.5).

Etapa 5: Chequeo automático complementario (secundario).. Como ejercicio de transparencia, y *no* como sustituto del juicio humano, el mismo corpus se procesó con un *pipeline* automático de dos niveles: (i) un filtro léxico local en tres niveles (L0: términos de exclusión de dominios ajenos; L1: presencia simultánea de vocabulario de pH/encalado y de proceso azucarero; L2: vocabulario de AA o de optimización), que resolvió 201 de 230 registros (87.4 %) como

EXCLUIR sin invocar al modelo; y (ii) un modelo de lenguaje local (Llama 3 8B, cuantización Q4_0, vía Ollama; $T = 0$) con un *prompt* de seis ejemplos sintéticos (Apéndice B) sobre los 29 registros restantes. Se fijó *a priori* un umbral de confianza de derivación de 55 %: un registro (una entrada de actas mal etiquetada como artículo) cayó por debajo y se trató como EXCLUIR; de los 28 restantes, el modelo clasificó 2 como INCLUIR y 26 como EXCLUIR. El *prompt* de producción contenía, como ejemplo positivo, un registro cuyo título, resumen y palabras clave reproducían los de uno de los estudios incluidos; esta fuga de información se evaluó en 2.8. Por ello, la concordancia modelo–humano se reporta solo como métrica secundaria de reproducibilidad algorítmica.

Etapa 6: Lectura a texto completo y extracción.. Los candidatos del doble cribado se leyeron a texto completo y los datos se extrajeron de los PDF originales (no de los resúmenes). La verificación confirmó **dos estudios incluidos**. La cadena acumulada es 541 → 353 → 239 → 230 → 2 (0.37 % del corpus bruto; 0.87 % del corpus Q1–Q4).

2.5 Fiabilidad del cribado

La fiabilidad se cuantificó en dos niveles. *Primario*: concordancia inter-humano entre los Revisores 1 y 2 sobre los 230 registros, mediante el κ de Cohen (McHugh, 2012), la concordancia observada P_0, la sensibilidad, la precisión y F_1 tomando la decisión consensuada como referencia, con intervalos de Wilson al 95 % (Wilson, 1927). Dado el desbalance esperado entre clases, se reportó también el índice PABAK $= 2P_0 - 1$ (Byrt et al., 1993), interpretado con la cautela descrita en la literatura sobre la paradoja del κ (Feinstein & Cicchetti, 1990). *Secundario*: la concordancia entre la decisión humana final y el *pipeline* automático (Apéndice D), etiquetada como ejercicio de reproducibilidad algorítmica y no como validación del cribado.

2.6 Extracción de datos y evaluación del riesgo de sesgo

Para los estudios incluidos se completó una matriz de extracción con metadatos, técnica de modelado y control, variables manipuladas, perturbaciones y controlada, origen de los datos, nivel de validación (simulación, banco de pruebas, planta piloto, planta industrial) y métricas reportadas. El nivel de madurez se expresó en la escala TRL de la NASA (National Aeronautics

and Space Administration, 2016). Dado el corpus reducido se planificó una síntesis narrativa (Lang et al., 2007; Yaffe et al., 2012). El riesgo de sesgo se evaluó con una herramienta *ad hoc* de cinco dominios (Apéndice C); su uso es opcional en PRISMA-ScR y no pretende ponderar los resultados.

2.7 Análisis bibliométrico y verificación léxica

Sobre el corpus Q1–Q4 ($n = 230$) se construyó una red de co-ocurrencia de palabras clave con *bibliometrix* (Aria & Cuccurullo, 2017) y *VOSviewer* (van Eck & Waltman, 2010); se retuvieron los 595 términos con frecuencia ≥ 2 y los 120 nodos de mayor grado ponderado. Las comunidades se detectaron con el algoritmo de Louvain (Blondel et al., 2008) y se reetiquetaron por su contenido dominante. Como la ausencia de un término en una red con umbral de frecuencia es evidencia indirecta, se añadió una **verificación léxica independiente**: sobre los 353 registros únicos, sin filtrar por tipo, año ni cuartil, se contó cuántos mencionan en título, resumen o palabras clave cada concepto núcleo de las RQ, solo y en co-presencia con vocabulario de pH/neutralización y de proceso azucarero (familias de expresiones regulares en el Apéndice F; *script* `12_auditoria_conceptual.py`).

2.8 Análisis de sensibilidad

Se realizaron tres análisis para acotar los sesgos de los criterios y del chequeo automático. (i) *Criterios de elegibilidad.* Entre los 353 registros únicos se identificaron, mediante la verificación léxica, los que combinan pH y proceso azucarero y no pasaron al cribado por tipo de documento o por carecer de cuartil; se leyeron por título y resumen y se caracterizaron descriptivamente (no constituyen un cribado formal ni entran en el cálculo de κ). (ii) *Filtro léxico local.* Los 201 registros resueltos por el filtro L0–L2 se re-examinaron con un criterio más laxo, sin las reglas L0 ni el requisito de vocabulario de AA, y los que combinaban pH y proceso azucarero se leyeron por título y resumen frente a los criterios. (iii) *Fuga en el prompt.* Los 29 registros que llegaron al modelo se re-procesaron con el *prompt* original y con uno corregido (ejemplo positivo sintético de otra familia metodológica), con el mismo modelo (resumen SHA-256 `365c0bd3c000...`), $T = 0$, y se compararon con la corrida de producción.

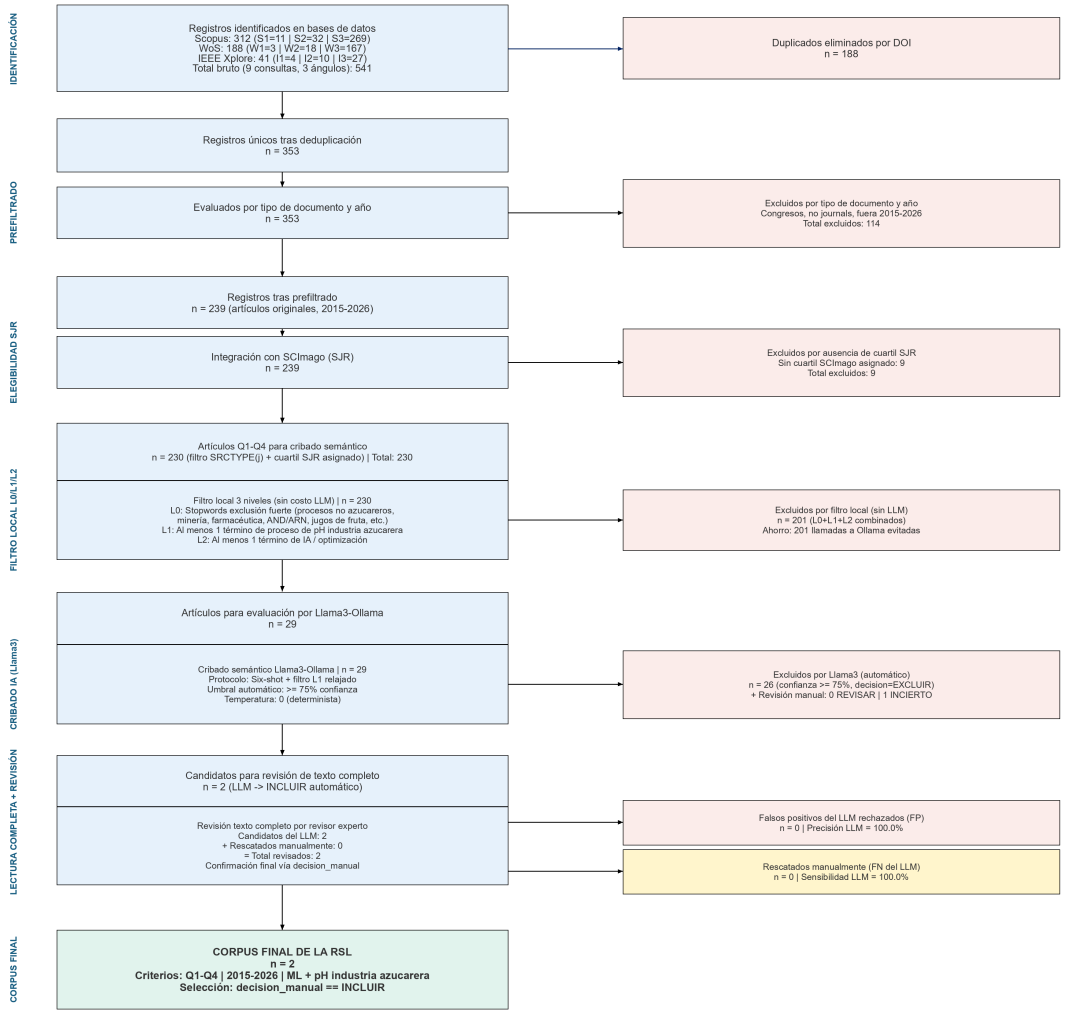
3 Resultados

3.1 Búsqueda y selección de estudios

La búsqueda identificó $N = 541$ registros en las tres bases originales (Scopus = 312; WoS = 188; IEEE Xplore = 41); las búsquedas en SciELO y LILACS no recuperaron ningún registro (0 resultados; Tabla A1), por lo que no modificaron el embudo. Tras eliminar 188 duplicados quedaron 353 registros únicos; el prefiltrado por tipo (48) y año (66) retuvo 239; y el filtro por cuartil, que excluyó 9 registros sin cuartil, dejó **230 artículos Q1–Q4** (130 Q1, 61 Q2, 21 Q3 y 18 Q4). El cribado doble confirmó **dos estudios incluidos**: Palacio-Morales et al., 2021, en una revista Q2, y Murugesan et al., 2020, en una revista Q3 (Figura 3).

Figura 3

Diagrama de flujo PRISMA-ScR de la revisión de alcance. Cadena verificada: $N_{bruto} = 541 \rightarrow n_{únicos} = 353 \rightarrow n_{prefiltrado} = 239 \rightarrow n_{Q1–Q4} = 230 \rightarrow n_{incluido} = 2$.



Nota. Elaboración propia. Adaptado de PRISMA-ScR (Tricco et al., 2018). Búsqueda ejecutada el 22 de junio de 2026; filtro de cuartil y cribado ejecutados en septiembre de 2026. La verificación léxica y el análisis de sensibilidad (2.8) no alteran el embudo.

3.2 Fiabilidad del cribado

Métrica primaria: κ inter-humano. Sobre los 230 registros, la concordancia entre los Revisores 1 y 2 fue $\kappa_{\text{inter}} = 1.000$, con concordancia observada 100 % (Tabla 2): no hubo ninguna discrepancia, de modo que la decisión consensuada coincide con la de ambos revisores. Respecto del consenso, la sensibilidad fue 100 %, la precisión 100 % y $F_1 = 1.000$, con IC 95 % de Wilson [34.2; 100] % para la sensibilidad y la precisión (2/2) y [98.4; 100] % para P_0 (230/230); $\text{PABAK}_{\text{inter}} = 1.000$. El corpus contiene 2 registros positivos (prevalencia 0.87 %): con tan pocos

positivos el intervalo de la sensibilidad es amplio, y un κ o PABAK máximos reflejan sobre todo la baja prevalencia y la facilidad de excluir los 228 registros claramente ajenos al tema, no concordancia sobre casos dudosos; el resultado debe leerse como estimación de la fiabilidad del proceso de exclusión y no como evidencia de desempeño sobre casos positivos. Una concordancia perfecta sin discrepancias, además, no permite estimar la variabilidad entre revisores.

Tabla 2

*Matriz de confusión **inter-humano** (Revisor 1 vs. Revisor 2) sobre los 230 registros del corpus Q1–Q4. Métrica primaria de fiabilidad del cribado.*

	Revisor 2 INCLUIR	**Revisor 2 EXCLUIR**	**Total**
Revisor 1 INCLUIR	2 [VP]	0 [FN]	2
Revisor 1 EXCLUIR	0 [FP]	228 [VN]	228
Total	**2**	**228**	**230**

Nota. VP: verdaderos positivos; VN: verdaderos negativos; FP: falsos positivos; FN: falsos negativos. $P_0 = 100\,\%$; $\kappa_{\text{inter}} = 1.000$; PABAK = 1.000.

Métrica secundaria: concordancia con el *pipeline* automático. En la corrida de producción el *pipeline* coincidió con la decisión humana final en los 230 registros ($\kappa = 1.000$). Sin embargo, esa cifra no es reproducible: al re-ejecutar los 29 registros que llegan al modelo con el mismo modelo, $T = 0$ y el *prompt* original, el modelo clasificó como INCLUIR un tercer registro (un estudio de clarificación de jugo con peróxido de hidrógeno y redes neuronales que la decisión humana final excluyó), lo que da 229/230 coincidencias ($\kappa = 0.798$, PABAK = 0.991). Con el *prompt* corregido, sin la fuga de información, el resultado fue idéntico (3 INCLUIR, 229/230), y el estudio de Palacio-Morales et al., 2021 se mantuvo como INCLUIR (confianza 95 → 98 %): la fuga no determinó su clasificación. El detalle está en el Apéndice D.

3.3 Los estudios incluidos

Los dos estudios (Tabla 3) abordan la regulación del pH en la clarificación del jugo con técnicas de control inteligente y optimización. Palacio-Morales et al., 2021, en *Processes* (MDPI;

Q2 SJR 2024), formula un NMPC cuyo modelo interno es un sistema difuso Takagi–Sugeno identificado y cuyos parámetros se sintonizan con una búsqueda de patrón sin gradiente; se evalúa sobre un modelo de planta *simulado* de invariantes de reacción y se compara con otras cinco sintonías de NMPC publicadas (no con un PID), con mejor índice ICET pero sobreimpulso equivalente y mayor esfuerzo de control que cuatro de ellas. Murugesan et al., 2020, en *Circuits, Systems, and Signal Processing* (Springer; Q3 SJR 2024), identifica un modelo de segundo orden del clarificador a partir de 3000 muestras reales de una planta y sintoniza fuera de línea un PID con un algoritmo de transición de estado, comparado con GA y PSO, con menor MSE y tiempo de asentamiento pero sin ventaja en el tiempo de subida. Ninguno implementó el control en lazo cerrado en planta (TRL $\approx$ 3–4); ambos usan optimización sin gradiente para sintonizar o identificar. El riesgo de sesgo (Apéndice C) fue moderado–alto para Palacio-Morales et al., 2021 y moderado para Murugesan et al., 2020.

Tabla 3: *Caracterización de los dos estudios incluidos, extraída del texto completo. Las cifras corresponden a la comparación intra-estudio reportada por los autores; no constituyen una síntesis entre estudios.*

Estudio	**Objetivo**	**Estrategia de modelado y control**	**Datos y variables**	**Resultados clave (intra-estudio)**	**Validación y limitaciones**
Palacio-Morales et al., 2021	Sintonizar un NMPC para regular el pH en la alcalinización del jugo de caña (*set-point* 7.34) tras identificar su modelo interno	Modelo interno Takagi–Sugeno de entrada–salida con conjuntos difusos multidimensionales (consecuentes lineales); identificación y sintonía del NMPC (horizontes y pesos) mediante búsqueda de patrón generalizada, sin gradiente	Planta **simulada** con un modelo de invariantes de reacción (HNO_3 + $NaHCO_3$) tomado de una tesis doctoral, no datos de planta. Manipulada: caudal de lechada de cal F_2 (10–70 GPM). Perturbaciones: caudal de jugo sulfitado F_1 (500–2100 GPM) y pH del jugo sulfitado y de la lechada. Salida: pH del jugo alcalinizado (5.7–8.7)	Índice ICET(pH) = 553 frente a 2.41–3.95 $\times 10^3$ de otras cinco sintonías de NMPC publicadas (menor es mejor). Sobreimpulso M_p = 30.3 % frente a 29.8–31.1 % (sin mejora). Esfuerzo de control 79.2 frente a 28.0–83.4 (mayor que el de cuatro de las cinco). **No se compara con un PID/PI**	Solo **simulación** (TRL ≈ 3–4, escala NASA NPR 7123.1B); sin planta piloto ni industrial. Los autores reportan rizado residual en la respuesta; el modelo de planta es un *benchmark* genérico, no un clarificador medido

Continued on next page

Tabla 3: *Caracterización de los dos estudios incluidos, extraída del texto completo. Las cifras corresponden a la comparación intra-estudio reportada por los autores; no constituyen una síntesis entre estudios.* (Continued)

Murugesan et al., 2020	Estimar los parámetros del modelo del clarificador y sintonizar fuera de línea un controlador PID para la neutralización del pH	Identificación estándar (modelo de segundo orden) refinada con un *state transition algorithm* con restricciones lagrangianas (LSTA); sintonía de K_p, T_i, T_d minimizando el MSE; comparación con GA y PSO	**Datos reales de planta** (M/S Sakthi Sugars Ltd.): 3000 muestras en dos turnos, 70 % entrenamiento y 30 % prueba. Entrada: caudal de lechada de cal. Salida: pH final del jugo	MSE 1.2×10^{-3} (LSTA) frente a 3.3×10^{-2} (GA) y 6.6×10^{-1} (PSO); tiempo de asentamiento 46.1 s frente a 52.2 y 94.8 s; tiempo de subida 33.4 s (LSTA) frente a 28.3 (GA) y 37.4 s (PSO), sin ventaja de LSTA en este índice	Identificación **fuera de línea con datos de planta**; el controlador solo se evalúa en **simulación** (respuesta a escalón), sin implementación en lazo cerrado (TRL $\approx$ 4). Modelo lineal de segundo orden para un proceso no lineal; el controlador es PID sintonizado por metaheurística

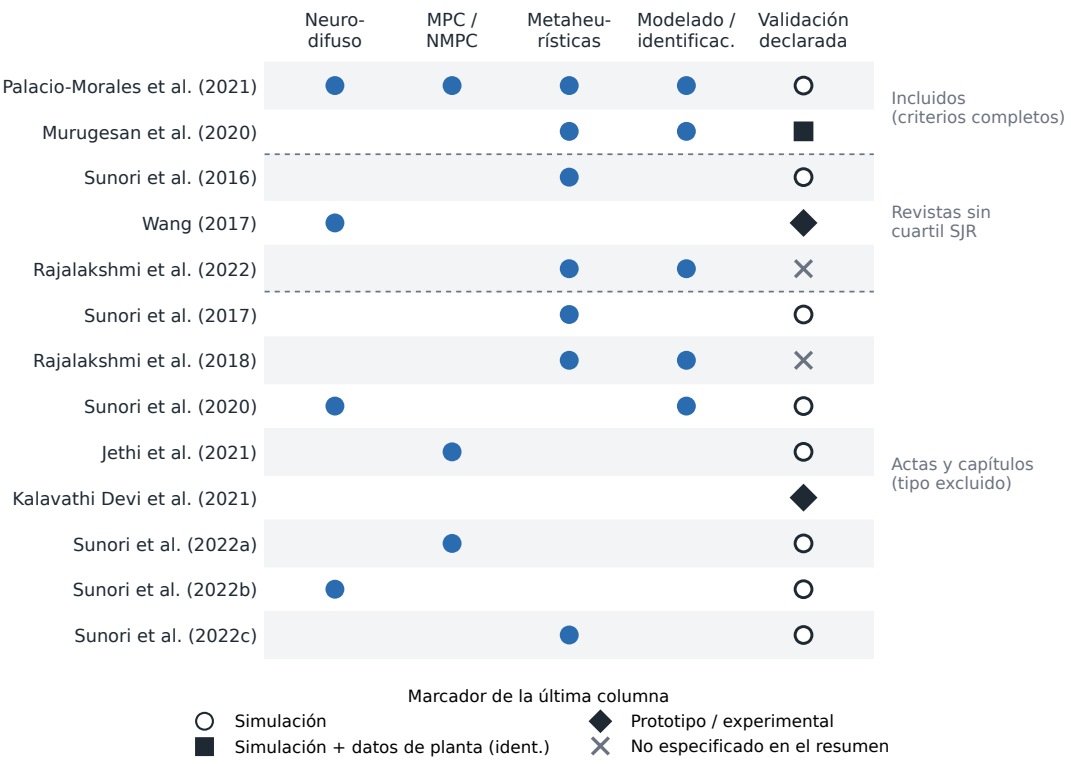
Nota. Elaboración propia a partir del texto completo de Palacio-Morales et al., 2021 (DOI: 10.3390/pr9122283) y Murugesan et al., 2020 (DOI: 10.1007/s00034-019-01139-5). Abreviaturas: NMPC = *nonlinear model predictive control*; ICET = integral del error cuadrático ponderado por el tiempo; GA = algoritmo genético; PSO = optimización por enjambre de partículas; TRL = *technology readiness level* (National Aeronautics and Space Administration, 2016). Las cifras se citan tal como las reportan los autores originales.

3.4 Evidencia *in-domain* excluida por criterios formales

El análisis de sensibilidad (2.8) identificó 11 trabajos que comparten con los incluidos el proceso (neutralización o clarificación del jugo azucarero), la variable (pH) y el uso de control avanzado o AA, pero que no cumplen los criterios formales: 3 artículos en revistas sin cuartil en SCImago 2024 y 8 actas o capítulos de series de libros (Apéndice F, Tabla F1). Se caracterizan de forma descriptiva a partir de sus resúmenes, no entran en el corpus incluido ni en el cálculo de κ, y la Figura 4 los sitúa junto a los dos incluidos. Un registro adicional sobre la defecosaturación de jugo de remolacha con una red neuronal (Vlasenko et al., 2023) no se contabiliza porque el pH es variable de entrada y no objetivo (criterio de exclusión e).

Figura 4

Mapa de evidencia in-domain sobre pH de la clarificación azucarera: los 2 estudios incluidos y los 11 trabajos excluidos por criterios formales, según familia de método y nivel de validación declarado.



Nota. Elaboración propia. Los dos incluidos se clasificaron con el texto completo; los 11 complementarios, solo con el resumen, por lo que "no especificado" indica que el resumen no declara el nivel de validación. Una fila puede aparecer en varias familias. Referencias completas en la Tabla F1 (Apéndice F).

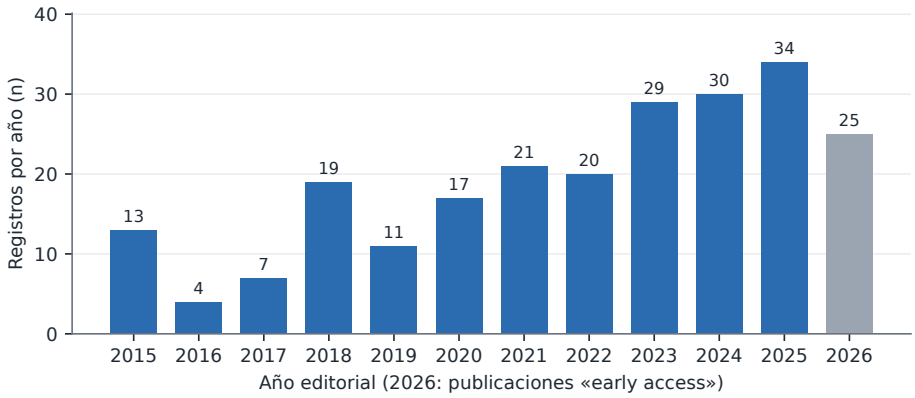
Tres rasgos caracterizan este conjunto de 13 trabajos (2016–2022): (i) **validación mayoritariamente en simulación**: de los 11 complementarios, 7 son simulaciones, 2 declaran prototipo o resultados experimentales sin precisar su escala (Kalavathi Devi et al., 2021; Wang, 2017) y 2 no especifican el nivel en el resumen; ninguno declara control en lazo cerrado en una planta industrial; (ii) **ausencia de aprendizaje por refuerzo y de sensores virtuales** de pH para uso en línea, pues el AA aparece solo como modelado (SVR, redes, ANFIS) o como optimizador; y (iii) **alta concentración autoral**: 10 de los 13 trabajos proceden de dos grupos de autores (7 del grupo Sunori–Juneja y 3 del grupo Rajalakshmi–Jeyadevi–Karthik, que incluye a Murugesan et al., 2020). Ningún trabajo *in-domain* identificado es posterior a 2022.

3.5 Caracterización bibliométrica del campo adyacente

El corpus Q1–Q4 (230 registros) crece de forma sostenida, con aceleración desde 2022: los años 2023–2026 concentran 118 registros (51.3 %), y los 25 de 2026 son publicaciones *early access* (Figura 5). Las revistas más frecuentes son de ciencia y tecnología de alimentos (*LWT* $n = 6$; *Food Chemistry* $n = 5$; *Bioresource Technology* $n = 5$; *Journal of Food Process Engineering* $n = 4$; *Biomass Conversion and Biorefinery* $n = 4$), sin presencia dominante de revistas de teoría de control.

Figura 5

Producción anual del corpus adyacente Q1–Q4 ($n = 230$; 2015–2026).



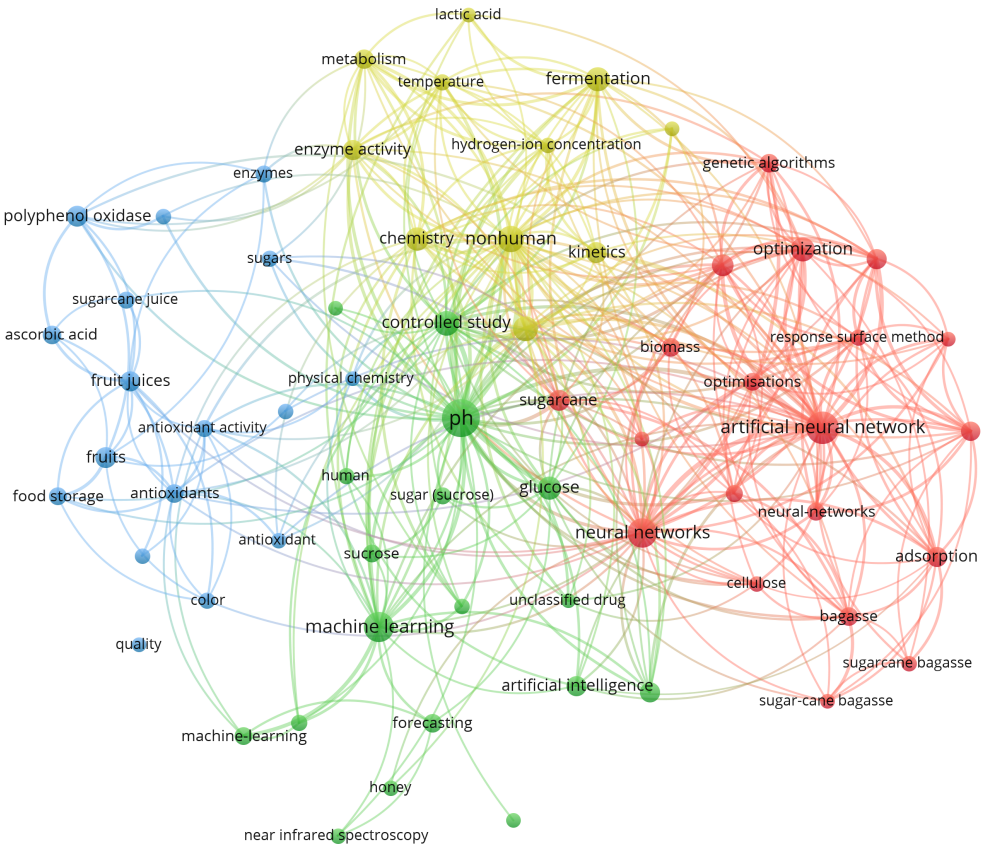
Nota. Elaboración propia a partir de `3.filtrado_quartiles.xlsx`. El crecimiento refleja el campo adyacente, no la regulación de pH del proceso azucarero, cuyos trabajos *in-domain* no superan el año 2022 (3.4).

La red de co-ocurrencia (120 nodos, 2403 aristas, densidad 0.337) identificó cuatro comu-

nidades por Louvain (Figura 6; Tabla 4). Las etiquetas automáticas del *pipeline*, orientadas *a priori* a las RQ, no describían los términos que dominan cada comunidad y se corrigieron por contenido real. La red incluye términos indexados por las bases (p. ej. *nonhuman*, *controlled study*, *unclassified drug*), ruido de indexación que impide leerla como mapa temático fino; por eso se usa para *caracterizar* el campo adyacente y no como prueba de la brecha, que descansa en el embudo (3.1) y en la verificación léxica (3.6).

Figura 6

Red de co-ocurrencia de palabras clave del corpus adyacente Q1–Q4 (n = 230; umbral ≥ 2; comunidades por Louvain). Ninguna de las cuatro comunidades corresponde a la intersección {AA/control avanzado × pH × industria azucarera}.



Nota. Elaboración propia con *bibliometrix* (Aria & Cuccurullo, 2017) y *VOSviewer* (van Eck & Waltman, 2010). El tamaño del nodo indica la frecuencia del término y el grosor de los enlaces la fuerza de co-ocurrencia. El vocabulario de los dos estudios incluidos (*pH neutralization*, *clarifier process*) tiene frecuencia 1 y queda bajo el umbral.

Tabla 4

Comunidades temáticas detectadas por Louvain sobre la red de co-ocurrencia del corpus Q1–Q4 (n = 230). Etiquetas corregidas por contenido dominante.

#	Etiqueta (por contenido real)	Términos dominantes	$N°$ térm.	Frec.
C1	Modelado ANN/GA/RSM y valorización de bagazo (optimización numérica de procesos)	neural network, artificial neural network, genetic algorithm, optimization, sugarcane, response surface methodology, adsorption, bagasse, biomass, cellulose, scanning electron microscopy, lignocellulose, saccharum	47	455
C2	ML/quimiometría para calidad de jugos y alimentos	fruits, polyphenol oxidase, fruit juices, juice quality, antioxidants, food storage, antioxidant activity, color, peroxidase, physicochemical properties, total soluble solids, shelf life	28	242
C3	Bioprocesos, cinética enzimática y química del azúcar	sugar, fermentation, prediction, kinetics, metabolism, enzymes, sugars, hydrogen-ion concentration, lactic acid, nitrogen, biosynthesis, substrate concentration	16	178
C4	Métodos de AA generales y espectroscopía no destructiva	machine learning, artificial intelligence, forecasting, sucrose, near infrared spectroscopy, honey, support vector machines, deep learning, chemometrics, random forest, partial least squares regression, principal component analysis	29	239

Nota. Elaboración propia. Ninguna comunidad corresponde a la intersección {AA/control avanzado × pH × industria azucarera}. El campo se organiza en torno a optimización numérica de modelos y valorización de bagazo (C1), calidad de jugos (C2), bioquímica y cinética enzimática (C3) y métodos generales de AA aplicados a espectroscopía (C4).

3.6 Verificación léxica y mapeo frente a las preguntas de investigación

La Tabla 5 combina las dos líneas de evidencia léxica: el conteo sobre los 353 registros únicos (verificación independiente del umbral ≥ 2) y la presencia en la red del corpus Q1–Q4. Los términos de aprendizaje por refuerzo no aparecen en ningún registro; *soft sensor* aparece en 5 registros, ninguno en contexto azucarero; y MPC/NMPC aparece en 5, de los cuales 4 son los ya identificados en 3.3 y 3.4. El vacío que indicaba la red a umbral ≥ 2 se confirma sin umbral, pero la verificación también muestra que el vocabulario de control avanzado *sí* existe en los registros *in-domain* excluidos por criterios formales.

Tabla 5

Verificación léxica de los conceptos núcleo de las RQ en los 353 registros únicos (título, resumen y palabras clave) y su presencia en la red del corpus Q1–Q4.

Concepto núcleo	**Registros**	**+ pH**	**+ proceso azucarero**	**+ pH y proceso azucarero**	**En la red Q1–Q4 (frec. ≥ 2)**
Sensor virtual / *soft sensor*	5	5	0	0	Ausente
MPC / NMPC	5	5	4	4	Ausente
Aprendizaje por refuerzo	0	0	0	0	Ausente
PID / PI	5	5	4	4	Ausente
Control difuso / neuro-difuso	16	16	8	8	Marginal
Metaheurísticas	45	45	12	12	Presente (optimización)
Control adaptativo / *gain scheduling*	2	2	1	1	Ausente
Gemelo digital	1	1	0	0	Ausente
Redes neuronales / AA general	221	210	28	25	Abundante

Nota. Elaboración propia (`12_auditoria_conceptual.py`). "Proceso azucarero" agrupa expresiones como *sugar mill*, *juice clarification*, *cane juice* o *sugar beet*; "pH" incluye neutralización, alcalinización y encalado. Del total de 353 registros, 64 combinan pH y proceso azucarero. Los términos de las palabras clave incluyen descriptores indexados por la base.

Traducido a las preguntas de investigación (Tabla 6), la evidencia es más densa de lo que sugería el corpus estricto en RQ1 y RQ2, pero poco madura en las tres.

Tabla 6

Estado de la evidencia por pregunta de investigación (corpus incluido y evidencia complementaria).

RQ	Evidencia *in-domain* (incluidos y complementarios)	Estado
RQ1	Identificación con datos de planta (Murugesan et al., 2020); modelos T–S, SVR y ANFIS sobre modelos simulados o sin datos declarados; ningún sensor virtual de pH para operación en línea	Evidencia parcial; madurez baja
RQ2	NMPC (Palacio-Morales et al., 2021), MPC y H_∞ frente a PID, ANFIS frente a PI y PID sintonizado por metaheurísticas, casi siempre en simulación sobre modelos de función de transferencia; sin comparación en planta	Evidencia existente; **brecha de validación**
RQ3	AA como modelado u optimizador; aprendizaje por refuerzo ausente; ningún estudio analiza barreras de adopción industrial	**Brecha mayor**

4 Discusión

4.1 Interpretación de la brecha

El hallazgo central es una **brecha cualificada**, no una ausencia de investigación. El corpus que cumple todos los criterios es de dos estudios, pero el análisis de sensibilidad muestra que existen al menos once trabajos más sobre el mismo problema, publicados en actas y en revistas sin cuartil. Lo que falta no es investigación sobre control avanzado del pH azucarero sino su *madurez y diversidad*: casi todo se valida en simulación sobre modelos de función de transferencia, no hay aprendizaje por refuerzo ni sensores virtuales operativos, no se documenta una línea base de PID en planta con la que medir la mejora, y la producción se concentra en dos grupos y no supera 2022, mientras el campo adyacente se acelera (51.3 % de los registros en 2023–2026). Un corpus mínimo bajo un protocolo auditable es informativo por sí mismo (Lang et al., 2007; Yaffe et al., 2012), pero solo si se acompaña de lo que aquí se hizo: reportar de forma explícita qué evidencia queda fuera por diseño y cuánto cambia la conclusión al incluirla.

Se examinaron explicaciones alternativas. *(a) Nicho demasiado estrecho; la transferencia directa basta.* Los propios estudios muestran que la transferencia *ya ocurrió en simulación*:

el modelo de planta de Palacio-Morales et al., 2021 es un *benchmark* de neutralización de invariantes de reacción (Gustafsson & Waller, 1983) y no un jugo de caña medido. Lo que no se ha demostrado es que los métodos funcionen con las particularidades del jugo (coloides, varios ácidos débiles, *fouling*); la brecha es empírica y de validación, no conceptual. *(b) El conocimiento existe, pero en canales de baja visibilidad.* Es coherente con la concentración en actas y en dos grupos. *(c) La práctica industrial no se publica.* Es plausible y no puede evaluarse con literatura indexada; se declara como limitación.

4.2 Métodos transferibles desde dominios vecinos

La analogía dinámica es el punto de partida: la curva de titulación del jugo comparte con la neutralización ácido–base genérica una ganancia variable en torno al punto de equivalencia (Shinskey, 1996). La Tabla 7 sintetiza, por familia de método, la evidencia de dominios vecinos, la evidencia *in-domain* hallada en esta revisión, la barrera principal y el horizonte propuesto.

Tabla 7

Matriz de transferibilidad de familias de métodos al encalado azucarero.

Familia	Dominios vecinos	*In-domain* (de 13)	Barrera principal en el encalado	Horizonte
Control difuso / neuro-difuso	Heredia-Molinero et al., 2014; Suguna et al., 2026	4 (modelo T–S, ANFIS, PID difuso)	Validación en lazo cerrado con datos reales; deriva del electrodo	Corto
Sensores virtuales / *data-driven*	Bardeeniz et al., 2025; Son et al., 2021; Xu et al., 2022	4 como modelado; 0 operativos	Datos etiquetados escasos; *fouling* y baja frecuencia de laboratorio	Corto
Metaheurísticas (identificación y sintonía)	No revisada (fuera del alcance de esta revisión)	7	Optimización fuera de línea sobre modelos simplificados; sin resintonía en línea	Corto
MPC / NMPC y caja gris	Berenguel et al., 2004; Durairaj et al., 2023; Henson y Seborg, 1994; Otálora et al., 2026	3	Modelo fiel con composición variable; costo de cómputo	Mediano
Aprendizaje por refuerzo	Alves Goulart y Dutra Pereira, 2020; Panjapornpon et al., 2022	0	Datos y exploración segura; requiere gemelo digital previo	Largo

Nota. Elaboración propia. Una referencia puede pertenecer a varias familias; los conteos *in-domain* provienen de la Figura 4. La selección de dominios vecinos es ilustrativa y no sistemática.

En el eje del **control predictivo**, el linaje que va de la identificación no lineal en tiempo real (Pröll & Nazmul Karim, 1994) y el control adaptativo basado en invariantes de reacción (Henson & Seborg, 1994) hasta los esquemas recientes con identificación por aprendizaje profundo (Durairaj et al., 2023) indica que el NMPC es viable si se dispone de un modelo suficientemente fiel, condición onerosa en el jugo de caña; los dos estudios incluidos abordan esa condición con identificación explícita, lo que motiva enfoques de caja gris que combinen invariantes de

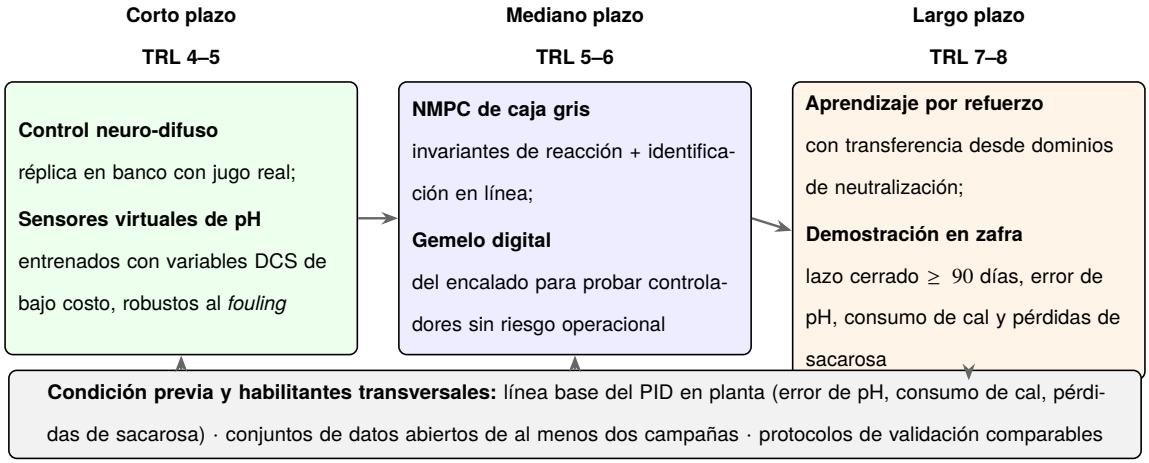
reacción con ajuste *data-driven*. En el eje del **control inteligente**, los controladores difusos y neuro-difusos diseñados para operar cerca del punto de equivalencia (Heredia-Molinero et al., 2014; Suguna et al., 2026) son pertinentes porque abordan la región de máxima sensibilidad. En el eje del **aprendizaje por refuerzo**, las políticas autónomas demostradas en efluentes y procesos multivariables (Alves Goulart & Dutra Pereira, 2020; Panjapornpon et al., 2022) requieren volúmenes de datos y exploración que chocan con la escasez de datos históricos etiquetados y con las restricciones operativas de un ingenio. Los **sensores virtuales** (Bardeeniz et al., 2025; Son et al., 2021; Xu et al., 2022) ofrecen una vía de menor riesgo frente al *fouling*. La transferibilidad no es uniforme: los enfoques difusos y los sensores virtuales son los de adopción más plausible a corto plazo; el NMPC exige resolver antes el modelado; y el aprendizaje por refuerzo depende de una infraestructura de datos aún inexistente en el sector.

4.3 Agenda de investigación

La agenda se organiza en tres horizontes y una condición habilitante previa (Figura 7).

Figura 7

Hoja de ruta propuesta por horizontes de madurez tecnológica (TRL), con las condiciones habilitantes transversales.



Nota. Elaboración propia. Las flechas indican dependencia: cada horizonte requiere los resultados del anterior. Los rangos TRL siguen la escala NASA (National Aeronautics and Space Administration, 2016).

Condición previa: línea base en planta. Cuantificar el desempeño de lazos PID en clarificadores industriales (error de pH, consumo de cal, pérdidas de sacarosa); sin ella ninguna mejora puede

medirse.

Corto plazo (TRL 4–5). (i) Réplica independiente en banco de pruebas de los estudios incluidos, con datos de jugo real, y formulaciones neuro-difusas adaptativas en la región del punto de equivalencia (Heredia-Molinero et al., 2014; Suguna et al., 2026). (ii) Sensores virtuales de pH entrenados con variables DCS de bajo costo (conductividad, turbidez, temperatura, Brix, caudal de cal) que den estimación continua cuando el electrodo deriva (Son et al., 2021; Xu et al., 2022).

Mediano plazo (TRL 5–6). (iii) NMPC de caja gris que integre el modelo físico de la curva de titulación con parámetros identificados en línea y sintonía por metaheurísticas, extendiendo los diseños de Palacio-Morales et al., 2021 y Murugesan et al., 2020. (iv) Gemelo digital de la sección de encalado para entrenar y probar controladores sin riesgo operacional.

Largo plazo (TRL 7–8). (v) Aprendizaje por refuerzo con transferencia desde dominios de neutralización, condicionado a gemelo digital y datos etiquetados. (vi) Conjuntos de datos abiertos con pH, alcalinidad, turbidez y color de al menos dos campañas completas. (vii) Demostración de control multiobjetivo en lazo cerrado durante ≥ 90 días de zafra, con registro de error de pH, consumo de cal, turbidez y pérdidas de sacarosa.

4.4 Fortalezas y limitaciones

Fortalezas. (1) Búsqueda en cinco bases con cadenas reproducibles (Apéndice A); (2) doble cribado humano ciego con fiabilidad cuantificada y declaración transparente de la fuga y la inestabilidad del chequeo automático; (3) extracción de los estudios incluidos desde el texto completo; (4) reporte explícito de la evidencia excluida por diseño y análisis de sensibilidad de los criterios; y (5) verificación léxica que no depende de umbrales de frecuencia.

Limitaciones. (a) *Criterios formales.* Los criterios de tipo de documento y de cuartil excluyen literatura relevante (11 trabajos); aunque se reportan por separado, su caracterización parte de resúmenes y no de un cribado formal. (b) *Registro retrospectivo y enmienda del protocolo.* El protocolo se registró en OSF después de la búsqueda, y la ampliación a Q1–Q4 fue posterior a un cribado preliminar (2.1); ambos hechos impiden presentar el diseño como preespecificado. (c) *Cláusulas* `AND NOT`. No se ejecutó una búsqueda de control sin ellas ni un rastreo de citas, por lo que puede haberse perdido algún registro. (d) *Fiabilidad con pocos positivos.* Ambos revisores

cribaron los 230 registros, pero con 2 positivos y ninguna discrepancia, κ y PABAK son máximos y los intervalos de la sensibilidad son amplios; la cifra no informa sobre la variabilidad entre revisores (Apéndice D). (e) *Cuartil único (2024)* aplicado a 2015–2026 y criterio *best quartile*, que puede sobrerrepresentar cuartiles altos. (f) *Bases e idioma.* No se consultó literatura gris ni repositorios institucionales y no se contactó a autores; la práctica industrial no publicada queda fuera. (g) *Red de palabras clave.* Incluye descriptores indexados que la vuelven ruidosa; se usa solo descriptivamente. (h) *Sesgo de concentración.* Diez de los 13 trabajos *in-domain* provienen de dos grupos; la brecha podría reflejar la actividad de pocos equipos. (i) *Chequeo con LLM.* Los modelos de lenguaje no son revisores independientes y no existen protocolos validados para su uso en cribado (Guo et al., 2024; Khraisha et al., 2024); el *prompt* de producción tuvo fuga de información, el modelo no fue reproducible entre corridas con $T = 0$ (κ de 1.000 a 0.798) y la etiqueta `llama3:latest` requiere fijar el resumen del modelo y la versión del servidor. Por eso solo se usa como métrica secundaria.

5 Conclusiones

Esta revisión de alcance cartografió la evidencia sobre AA y control avanzado para el pH de la clarificación azucarera. Respondiendo a las preguntas de investigación:

1. **RQ1 — Modelado y sensores virtuales.** Se ha modelado el proceso con identificación de segundo orden a partir de datos de planta (Murugesan et al., 2020), modelos Takagi–Sugeno, SVR y ANFIS; no existe un sensor virtual de pH para uso en línea.

2. **RQ2 — Control avanzado frente a PID.** Dos estudios cumplen todos los criterios (NMPC con identificación difusa y PID sintonizado por metaheurística) y otros 11 los incumplen formalmente; casi todos se validan en simulación y ninguno documenta el control en planta ni una línea base de PID industrial.

3. **RQ3 — AA, refuerzo y barreras.** El AA aparece como modelado u optimizador; el aprendizaje por refuerzo está ausente y ningún estudio analiza las barreras de adopción.

La brecha identificada es de **madurez y de diversidad metodológica**, no de ausencia de investigación: el problema se ha abordado en simulación por un número reducido de grupos,

sin llegar a la validación industrial. La contribución metodológica es mostrar cuánto depende esta conclusión de los criterios de elegibilidad y reportar la evidencia que queda fuera. La prioridad es establecer una línea base de PID en planta y validar en banco y en planta los enfoques neuro-difusos y los sensores virtuales, antes de NMPC de caja gris y aprendizaje por refuerzo (Figura 7). Esta conclusión se limita al corpus indexado y a la evidencia accesible por título y resumen (4.4).

Contribución de los autores

A. Castillo: conceptualización, curación de datos, análisis formal, investigación, metodología, administración del proyecto, recursos, software, supervisión, validación, visualización, redacción del borrador original, revisión y edición.

D. Barreto: curación de datos, validación, investigación (cribado independiente del corpus Q1–Q4 completo, $n = 230$), revisión y edición.

Aprobación ética. Esta investigación es una revisión de literatura publicada y no involucra participantes humanos ni animales; por tanto, no requiere aprobación de comité de ética.

References

Alves Goulart, D., & Dutra Pereira, R. (2020). Autonomous pH control by reinforcement learning for electroplating industry wastewater. *Computers and Chemical Engineering*, *140*. https://doi.org/10.1016/j.compchemeng.2020.106909

Aria, M., & Cuccurullo, C. (2017). bibliometrix: An R-tool for comprehensive science mapping analysis. *Journal of Informetrics*, *11*(4), 959-975. https://doi.org/10.1016/j.joi.2017.08.007

Arksey, H., & O'Malley, L. (2005). Scoping studies: towards a methodological framework. *International Journal of Social Research Methodology*, *8*(1), 19-32. https://doi.org/10.1080/1364557032000119616

Bardeeniz, S., Panjapornpon, C., Hounkim, W., Dechakupt, T., & Tawai, A. (2025). Artificial intelligence-driven control for enhancing carbon dioxide-based wastewater pH regulation in tubular reactor. *Computers and Chemical Engineering*, *192*. https://doi.org/10.1016/j.compchemeng.2024.108880

Berenguel, M., Rodríguez, F., Acién, F., & García, J. (2004). Model predictive control of pH in tubular photobioreactors. *Journal of Process Control*, *14*(4), 377-387. https://doi.org/10.1016/j.jprocont.2003.07.001

Blondel, V. D., Guillaume, J.-L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, *2008*(10), P10008. https://doi.org/10.1088/1742-5468/2008/10/P10008

Byrt, T., Bishop, J., & Carlin, J. B. (1993). Bias, prevalence and kappa. *Journal of Clinical Epidemiology*, *46*(5), 423-429. https://doi.org/10.1016/0895-4356(93)90018-V

Durairaj, S., Xavier, J., Patnaik, S., & Panda, R. (2023). Deep Learning Based System Identification and Nonlinear Model Predictive Control of pH Neutralization Process. *Industrial and Engineering Chemistry Research*, *62*(33), 13061-13080. https://doi.org/10.1021/acs.iecr.3c01212

Feinstein, A. R., & Cicchetti, D. V. (1990). High agreement but low Kappa: I. the problems of two paradoxes. *Journal of Clinical Epidemiology*, *43*(6), 543-549. https://doi.org/10.1016/0895-4356(90)90158-L

García, C. E., Prett, D. M., & Morari, M. (1989). Model predictive control: Theory and practice – A survey. *Automatica*, *25*(3), 335-348. https://doi.org/10.1016/0005-1098(89)90002-2

Guo, E., Gupta, M., Deng, J., Park, Y.-J., Paget, M., & Naugler, C. (2024). Automated Paper Screening for Clinical Reviews Using Large Language Models: Data Analysis Study. *Journal of Medical Internet Research*, *26*, e48996. https://doi.org/10.2196/48996

Gustafsson, T. K., & Waller, K. V. (1983). Dynamic modeling and reaction invariant control of pH. *Chemical Engineering Science*, *38*(3), 389-398. https://doi.org/10.1016/0009-2509(83)80157-2

Henson, M., & Seborg, D. (1994). Adaptive nonlinear control of a pH neutralization process. *IEEE Transactions on Control Systems Technology*, *2*(3), 169-182. https://doi.org/10.1109/87.317975

Heredia-Molinero, M., Sánchez-Prieto, J., Briongos, J., & Palancar, M. (2014). Feedback PID-like fuzzy controller for pH regulatory control near the equivalence point. *Journal of Process Control*, *24*(7), 1023-1037. https://doi.org/10.1016/j.jprocont.2014.05.006

Hurowitz, S., Bobkov, A., & Riggs, J. (2000). pH control using advanced proportional-integral controls with the dual- injection in-line process. *Industrial and Engineering Chemistry Research*, *39*(7), 2418-2426. https://doi.org/10.1021/ie980776x

Jethi, G. S., Sunori, S. K., Tewari, M., Goyal, P., Maurya, S., & Arora, S. (2021). Design and Analysis of Prediction based Control System for pH Neutralization Process of Sugar Mill. *2021 2nd Global Conference for Advancement in Technology (GCAT)*, 1-6. https://doi.org/10.1109/GCAT52182.2021.9587748

Kalavathi Devi, T., Mouleeshuwarapprabhu, R., Uma Devi, S., Sakthivel, P., Poojashri, V., Swetha, A., & Vasuki, P. (2021). Sensor Technology and Regulation method for Sustaining the pH value in Sugar Mechanized Process. *2021 Fourth International Conference on Electrical, Computer and Communication Technologies (ICECCT)*, 1-5. https://doi.org/10.1109/ICECCT52121.2021.9616891

Khraisha, Q., Put, S., Kappenberg, J., Warraitch, A., & Hadfield, K. (2024). Can large language models replace humans in systematic reviews? Evaluating GPT -4's efficacy in screening and extracting data from peer-reviewed and grey literature in multiple languages. *Research Synthesis Methods*, *15*(4), 616-626. https://doi.org/10.1002/jrsm.1715

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems 25 (NIPS 2012)*, 1097-1105.

Lang, A., Edwards, N., & Fleiszer, A. (2007). Empty systematic reviews: hidden perils and lessons learned. *Journal of Clinical Epidemiology*, *60*(6), 595-597. https://doi.org/10.1016/j.jclinepi.2007.01.014

Levac, D., Colquhoun, H., & O'Brien, K. K. (2010). Scoping studies: advancing the methodology. *Implementation Science*, *5*(1), 69. https://doi.org/10.1186/1748-5908-5-69

McHugh, M. L. (2012). Interrater reliability: the kappa statistic. *Biochemia Medica*, *22*(3), 276-282. https://doi.org/10.11613/BM.2012.031

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, *518*(7540), 529-533. https://doi.org/10.1038/nature14236

Munn, Z., Peters, M. D., Stern, C., Tufanaru, C., McArthur, A., & Aromataris, E. (2018). Systematic review or scoping review? Guidance for authors when choosing between a systematic or scoping review approach. *BMC Medical Research Methodology*, *18*, 143. https://doi.org/10.1186/s12874-018-0611-x

Murugesan, R., Solaimalai, J., & Chandran, K. (2020). Computer-Aided Controller Design for a Nonlinear Process Using a Lagrangian-Based State Transition Algorithm. *Circuits, Systems, and Signal Processing*, *39*(2), 977-996. https://doi.org/10.1007/s00034-019-01139-5

National Aeronautics and Space Administration. (2016). *NASA Space Flight Program and Project Management Requirements (NPR 7123.1B): NASA Systems Engineering Processes and Requirements* (inf. téc. N.º NPR 7123.1B). NASA Headquarters.

Otálora, P., Banerjee, S., Mistiri, M., Khan, O., Rivera, D., & Guzmán, J. (2026). Enhancing pH control in microalgae raceway photobioreactors using 3DoF-KF model-on-demand model predictive control. *Control Engineering Practice*, *168*. https://doi.org/10.1016/j.conengprac.2025.106742

Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... Moher, D. (2021). The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, n71. https://doi.org/10.1136/bmj.n71

Palacio-Morales, J., Tobón, A., & Herrera, J. (2021). Optimization based on pattern search algorithm applied to ph non-linear control: Application to alkalinization process of sugar juice. *Processes*, *9*(12), 2283. https://doi.org/10.3390/pr9122283

Palancar, M., Aragón, J., & Torrecilla, J. (1998). PH-control system based on artificial neural networks. *Industrial and Engineering Chemistry Research*, *37*(7), 2729-2740. https://doi.org/10.1021/ie970718w

Panjapornpon, C., Chinchalongporn, P., Bardeeniz, S., Makkayatorn, R., & Wongpunnawat, W. (2022). Reinforcement Learning Control with Deep Deterministic Policy Gradient Algorithm for Multivariable pH Process. *Processes*, *10*(12). https://doi.org/10.3390/pr10122514

Peters, M. D. J., Godfrey, C., McInerney, P., Munn, Z., Tricco, A. C., & Khalil, H. (2020). Scoping reviews. En E. Aromataris & Z. Munn (Eds.), *JBI Manual for Evidence Synthesis*. JBI. https://doi.org/10.46658/JBIMES-20-12

Pröll, T., & Nazmul Karim, M. (1994). Model-predictive pH control using real-time NARX approach. *AIChE Journal*, *40*(2), 269-282. https://doi.org/10.1002/aic.690400207

Rajalakshmi, M., Jeyadevi, S., & Karthik, C. (2018). An Application Of Hybrid Firefly And Pso With Support Vector Regression For Modeling A Clarifier Process In Sugar Industry. *2018 National Power Engineering Conference (NPEC)*, 1-10. https://doi.org/10.1109/NPEC.2018.8476695

Rajalakshmi, M., Saravanan, V., Arunprasad, V., A. T. Romero, C., I. Khalaf, O., & Karthik, C. (2022). Machine Learning for Modeling and Control of Industrial Clarifier Process. *Intelligent Automation & Soft Computing*, *32*(1), 339-359. https://doi.org/10.32604/iasc.2022.021696

Rein, P. (2007). *Cane Sugar Engineering*. Bartens.

Shinskey, F. G. (1996). *Process Control Systems: Application, Design, and Tuning* (4.ª ed.). McGraw-Hill.

Son, M., Yoon, N., Jeong, K., Abass, A., Logan, B., & Cho, K. (2021). Deep learning for pH prediction in water desalination using membrane capacitive deionization. *Desalination*, *516*. https://doi.org/10.1016/j.desal.2021.115233

Suguna, R., Thankaraj, B., Kothandaraman, U., & Jeevananthan, M. (2026). Advanced adaptive neuro-fuzzy inference system controller for optimizing pH neutralization process control. *Canadian Journal of Chemical Engineering*, *104*(2), 864-885. https://doi.org/10.1002/cjce.70053

Sunori, S., Juneja, P., Chaturvedi, M., & Bisht, S. (2016). GA based Optimization of Control System Performance for Juice Clarifier of Sugar Mill. *Oriental Journal of Chemistry*, *32*(4), 2205-2208. https://doi.org/10.13005/ojc/320451

Sunori, S. K., Bhakuni Negi, P., Arora, S., Khan, F., Maurya, S., Juneja, P., Manu, M., & Ghai, K. (2022). Neuro-fuzzy Controller Design for pH Control in Sugar Refineries. *2022 8th International Conference on Advanced Computing and Communication Systems (ICACCS)*, 197-202. https://doi.org/10.1109/ICACCS54159.2022.9785146

Sunori, S. K., Jethi, G. S., Bhakuni, A. S., & Juneja, P. K. (2020). Neuro-Fuzzy Modeling of PH Neutralization Process in Sugar Mill. *2020 International Conference on Advances in Computing, Communication & Materials (ICACCM)*, 95-98. https://doi.org/10.1109/ICACCM50413.2020.9213034

Sunori, S. K., Joshi, K. A., Negi, P. B., Mittal, A., Garia, P., Maurya, S., & Juneja, P. (2022). Design of Digital and Robust Control Systems for Sugar Refinery. *2022 4th International Conference on Smart Systems and Inventive Technology (ICSSIT)*, 527-532. https://doi.org/10.1109/ICSSIT53264.2022.9716315

Sunori, S. K., Juneja, P. K., Chaturvedi, M., & Saini, P. (2017). Model Order Reduction of a Higher Order Model of pH Neutralizer of Sugar Mill. *2016 8th International Conference on Computational Intelligence and Communication Networks (CICN)*, 653-656. https://doi.org/10.1109/CICN.2016.134

Sunori, S. K., Negi, P. B., Mittal, A., Bhawana, Goyal, P., & Juneja, P. K. (2022). Soft Computing-Based Optimization of pH Control System of Sugar Mill. En *Lecture Notes in Networks and Systems* (pp. 271-281). Springer Nature Singapore. https://doi.org/10.1007/978-981-16-2126-0_24

Tricco, A. C., Lillie, E., Zarin, W., O'Brien, K. K., Colquhoun, H., Levac, D., Moher, D., Peters, M. D., Horsley, T., Weeks, L., et al. (2018). PRISMA Extension for Scoping

Reviews (PRISMA-ScR): Checklist and Explanation. *Annals of Internal Medicine*, *169*(7), 467-473. https://doi.org/10.7326/M18-0850

van Eck, N. J., & Waltman, L. (2010). VOSviewer: Visualizing Scientific Landscapes.

Vlasenko, L., Zaiets, N., Lutska, N., & Savchuk, O. (2023). Neural Network Model for Predicting the Resource Efficiency of the Defecosaturation Department of a Sugar Factory. En *Lecture Notes in Networks and Systems* (pp. 121-131). Springer International Publishing. https://doi.org/10.1007/978-3-031-19958-5_12

Wang, Z. (2017). The pH value control of clarifying process in sugar refinery based on fuzzy control. *Acta Technica CSAV (Ceskoslovensk Akademie Ved)*, *62*(1), 433-446.

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, *22*(158), 209-212. https://doi.org/10.1080/01621459.1927.10502953

Xu, Y., Zeng, X., Bernard, S., & He, Z. (2022). Data-driven prediction of neutralizer pH and valve position towards precise control of chemical dosage in a wastewater treatment plant. *Journal of Cleaner Production*, *348*. https://doi.org/10.1016/j.jclepro.2022.131360

Yaffe, J., Montgomery, P., Hopewell, S., & Shepard, L. D. (2012). Empty reviews: a description and consideration of Cochrane systematic reviews with no included studies. *PLoS ONE*, *7*(5), e36626. https://doi.org/10.1371/journal.pone.0036626

Appendix A. Consultas booleanas por base de datos

Se reproducen las tres consultas booleanas, mapeadas 1-a-1 con las tres preguntas de investigación (RQ1 modelado y sensores virtuales; RQ2 control avanzado frente a PID; RQ3 ML/RL/híbridos y barreras de adopción). Todas las cadenas se ejecutaron el 22 de junio de 2026 sobre las cinco bases de datos (Scopus, Web of Science, IEEE Xplore, SciELO, LILACS) con ventana temporal 2015–2026 (incluyendo registros *early access* con año editorial 2026). La sintaxis por base se ajustó al motor correspondiente conservando el mismo alcance semántico: Scopus utilizó el campo `TITLE-ABS-KEY(...)`; Web of Science empleó `TS=(...)` (*Topic*); IEEE Xplore usó operadores directos sobre *All Metadata*; SciELO empleó el campo `(ti,ab)` con operadores booleanos estándar; LILACS empleó búsqueda por DeCS (Descriptores en Ciencias de la Salud) con operadores booleanos y `AND NOT` sustituido por `NOT`.

Tabla A1

Recuentos verificados por base de datos y consulta ($N = 541$ en las tres bases originales; 0 en SciELO y 0 en LILACS; búsqueda del 22 de junio de 2026, ventana 2015–2026).

Base	Consulta	Foco (RQ)	*n*
Scopus	Q1	pH, sensores virtuales e identificación (RQ1)	11
	Q2	Control avanzado y metaheurísticas vs. PID (RQ2)	32
	Q3	ML/RL/híbridos y barreras (RQ3)	269
		Subtotal Scopus	**312**
Web of Science	Q1	pH, sensores virtuales e identificación (RQ1)	3
	Q2	Control avanzado y metaheurísticas vs. PID (RQ2)	18
	Q3	ML/RL/híbridos y barreras (RQ3)	167
		Subtotal WoS	**188**
IEEE Xplore	Q1	pH, sensores virtuales e identificación (RQ1)	4
	Q2	Control avanzado y metaheurísticas vs. PID (RQ2)	10
	Q3	ML/RL/híbridos y barreras (RQ3)	27
		Subtotal IEEE	**41**
Total bruto original (3 bases)			**541**
SciELO	Q4	Adaptación combinada de Q1+Q2+Q3 a sintaxis (ti,ab) con operadores booleanos	0
		Subtotal SciELO	**0**
LILACS	Q4	Adaptación combinada a DeCS (Descriptores en Ciencias de la Salud) con operadores booleanos	0
		Subtotal LILACS	**0**
Total bruto ampliado (5 bases)			**541**
Tras deduplicación por DOI y *fuzzy match* de títulos			**353**

Nota. La deduplicación combinó emparejamiento exacto por DOI y *fuzzy match* de títulos con umbral $\geq 95\,\%$ (*rapidfuzz*), reduciendo falsos negativos por variaciones tipográficas entre RIS de distintas fuentes. La tasa de solapamiento inter-base en las tres bases originales ($34.8\,\% = 188/541$) es consistente con una estrategia de búsqueda estable y con convergencia de un núcleo común de literatura entre las tres bases. Las consultas SciELO y LILACS se diseñaron como una única consulta combinada Q4 por base, adaptando los elementos semánticos comunes de Q1+Q2+Q3 a la sintaxis local (operadores booleanos, campos disponibles).

Tabla A2

Cadenas específicas para SciELO y LILACS con sintaxis local (consulta combinada Q4; elementos semánticos comunes de Q1+Q2+Q3).

Base	Cadena (sintaxis local)
SciELO	`(ti:("pH control" OR "pH monitoring" OR "pH prediction" OR "pH regulation" OR "acidity control" OR "alkalinity control" OR "lime dosage" OR "calcium hydroxide" OR "milk of lime") AND ab:("sugar mill" OR "sugarcane" OR "cane juice" OR "sugar juice" OR "sugar industry" OR "juice clarification" OR "liming process" OR "defecation" OR "sulfitation" OR "sugar beet" OR "sugar factory" OR "saccharum") AND (ti:("soft sensor" OR "virtual sensor" OR "identification" OR "neural network" OR "LSTM" OR "predictive model" OR "model predictive control" OR "NMPC" OR "fuzzy logic" OR "machine learning" OR "deep learning" OR "reinforcement learning" OR "digital twin") OR ab:("soft sensor" OR "virtual sensor" OR "identification" OR "neural network" OR "LSTM" OR "predictive model" OR "model predictive control" OR "NMPC" OR "fuzzy logic" OR "machine learning" OR "deep learning" OR "reinforcement learning" OR "digital twin"))) NOT (ti:("wastewater" OR "soil pH" OR "fermentation broth" OR "bioethanol" OR "pharmaceutical" OR "bioreactor" OR "wine" OR "beer" OR "dairy") OR ab:("wastewater" OR "soil pH" OR "fermentation broth" OR "bioethanol" OR "pharmaceutical" OR "bioreactor" OR "wine" OR "beer" OR "dairy"))`
LILACS (DeCS)	`("Controle de pH" OR "monitoramento de pH" OR "previsão de pH" OR "regulação de pH" OR "controle de acidez" OR "dosagem de cal" OR "hidróxido de cálcio" OR "leite de cal" OR "pH control" OR "pH monitoring" OR "pH prediction" OR "pH regulation" OR "acidity control" OR "lime dosage" OR "calcium hydroxide" OR "milk of lime") AND ("usina de açúcar" OR "cana-de-açúcar" OR "caldo de cana" OR "suco de cana" OR "indústria açucareira" OR "clarificação de caldo" OR "calagem" OR "defecação" OR "sulfitação" OR "beterraba açucareira" OR "sugar mill" OR "sugarcane" OR "cane juice" OR "sugar juice" OR "sugar industry" OR "juice clarification" OR "liming process" OR "defecation" OR "sulfitation" OR "sugar beet" OR "sugar factory" OR "saccharum") AND ("sensor virtual" OR "sensor suave" OR "identificação de sistemas" OR "rede neural" OR "LSTM" OR "modelo preditivo" OR "controle preditivo de modelo" OR "NMPC" OR "lógica fuzzy" OR "aprendizado de máquina" OR "aprendizado profundo" OR "aprendizado por reforço" OR "gêmeo digital" OR "soft sensor" OR "virtual sensor" OR "identification" OR "neural network" OR "model predictive control" OR "fuzzy logic" OR "machine learning" OR "deep learning" OR "reinforcement learning" OR "digital twin") NOT ("águas residuais" OR "pH do solo" OR "caldo de fermentação" OR "bioetanol" OR "farmacêutico" OR "biorreator" OR "vinho" OR "cerveja" OR "laticínios" OR "wastewater" OR "soil pH" OR "fermentation broth" OR "bioethanol" OR "pharmaceutical" OR "bioreactor" OR "wine" OR "beer" OR "dairy")`

Nota. Elaboración propia. La consulta Q4 combina los elementos semánticos comunes de Q1, Q2 y Q3 en una sola cadena por base, ajustándose a la sintaxis local. SciELO emplea operadores `(ti:)` (título) y `(ab:)` (resumen) con booleanos estándar; `AND NOT` se sustituye por `NOT`. LILACS emplea descriptores DeCS bilingües (portugués + español) para máxima sensibilidad regional; los términos en inglés se mantienen como refuerzo. Los recuentos se reportan en la Tabla A1.

Q1 — Modelado y sensores virtuales de pH (RQ1)

```
TITLE-ABS-KEY(
  ("pH control" OR "pH monitoring" OR "pH prediction"
   OR "pH optimization" OR "pH regulation" OR "pH measurement"
   OR "pH adjustment" OR "pH correction" OR "acidity control"
   OR "alkalinity control" OR "juice acidity"
   OR "lime dosage" OR "lime addition"
   OR "calcium hydroxide" OR "milk of lime")
  AND
  ("sugar mill" OR "sugarcane" OR "cane juice"
   OR "sugar juice" OR "sugar industry"
   OR "juice clarification" OR "liming process"
   OR "defecation" OR "sulfitation"
   OR "sugar beet" OR "beet sugar"
   OR "sugar factory" OR "saccharum")
  AND
  ("soft sensor" OR "virtual sensor" OR "inferential sensor"
   OR "identification" OR "data-driven model" OR "data-driven"
   OR "online estimation" OR "real-time estimation"
   OR "neural network" OR "LSTM"
   OR "predictive model" OR "regression model")
)
AND NOT TITLE-ABS-KEY(
  "wastewater" OR "water treatment" OR "soil pH" OR "blood pH"
  OR "fermentation broth" OR "bioethanol"
  OR "pharmaceutical" OR "bioreactor"
  OR "wine" OR "beer" OR "dairy" OR "groundwater"
)
```

Listing 1: Cadena Q1 (Scopus). Las cadenas equivalentes para WoS e IEEE Xplore se obtienen sustituyendo el operador de campo (`TS=` en WoS; sin prefijo en IEEE).

Q2 — Control avanzado (NMPC/Fuzzy/metaheurísticas) vs. PID (RQ2)

```
TITLE-ABS-KEY(
```

```
  ("model predictive control" OR "NMPC" OR "nonlinear MPC"
   OR "fuzzy logic" OR "takagi-sugeno" OR "neuro-fuzzy"
   OR "adaptive control" OR "intelligent control"
   OR "PID tuning" OR "optimal control"
   OR "pattern search" OR "particle swarm"
   OR "genetic algorithm" OR "differential evolution"
   OR "bayesian optimization")
  AND "pH"
  AND ("sugar mill" OR "sugarcane" OR "cane juice"
       OR "sugar juice" OR "juice clarification"
       OR "liming process" OR "defecation" OR "sulfitation"
       OR "sugar industry" OR "sugar beet" OR "sugar factory")
)
AND NOT TITLE-ABS-KEY(
  "wastewater" OR "bioethanol" OR "fermentation broth"
  OR "pharmaceutical" OR "soil" OR "blood"
  OR "wine" OR "dairy" OR "desalination"
  OR "anaerobic digestion" OR "bioreactor"
)
```

Listing 2: Cadena Q2 (Scopus).

Q3 — ML/RL/híbridos y barreras de adopción (RQ3)

```
TITLE-ABS-KEY(
  ("machine learning" OR "deep learning" OR "neural network"
   OR "artificial intelligence" OR "random forest"
   OR "gradient boosting" OR "XGBoost" OR "lightGBM"
   OR "support vector"
   OR "reinforcement learning" OR "deep reinforcement learning"
   OR "DDPG" OR "PPO" OR "Q-learning"
   OR "hybrid model" OR "grey-box model" OR "physics-informed"
   OR "digital twin" OR "transfer learning")
  AND "pH"
  AND ("sugar" OR "sugarcane" OR "cane juice"
       OR "sugar juice" OR "clarification"
```

```
      OR "liming" OR "sugar mill" OR "sugar industry"
      OR "sugar beet" OR "juice purification"
      OR "sugar factory" OR "defecation")
)
AND NOT TITLE-ABS-KEY(
  "wastewater" OR "bioethanol" OR "pharmaceutical"
  OR "soil" OR "blood" OR "bioreactor" OR "desalination"
  OR "wine" OR "beer" OR "fermentation broth"
)
```

Listing 3: Cadena Q3 (Scopus).

Appendix B. *Prompt* del chequeo automático complementario y análisis de sensibilidad

Función y advertencias. El *prompt* que sigue se empleó *exclusivamente* como chequeo automático complementario (Etapa 5, 2.4); no es una etapa de cribado ni sustituye el juicio humano, cuya autoridad reside en el doble cribado de la Etapa 4. Se reproduce tal como lo ejecuta el *script* `04_filtrado_ollama.py` (modelo servido por Ollama con $T = 0$; salida JSON). Conviene precisar tres hechos para su correcta interpretación:

1. Los seis ejemplos son **sintéticos**: no corresponden a publicaciones reales, y sus cifras (p. ej., "MAE= 0.04") son ilustrativas.
2. El **Ejemplo 3** reproduce el título, un resumen parafraseado y las palabras clave de uno de los estudios incluidos (Palacio-Morales et al., 2021). Es una **fuga de información**: el modelo recibió como ejemplo positivo el estudio que luego clasificó como positivo. Su efecto se evaluó re-ejecutando el *pipeline* sin la fuga (Tabla B1).
3. El criterio de cuartil SJR **no forma parte del *prompt***; se aplica antes (Etapa 3).

```
Actua como revisor experto en una revision sistematica
(RSL) sobre APRENDIZAJE AUTOMATICO aplicado al CONTROL DE
pH EN LA INDUSTRIA AZUCARERA (clarificacion, encalado,
sulfitacion, purificacion del jugo de cana y remolacha).

=== EJEMPLOS DE REFERENCIA (six-shot) ===
```

```
EJEMPLO 1 - INCLUIR (sintetico: ANN para prediccion de pH)
Titulo: "Artificial neural network for real-time pH
        prediction in sugarcane juice clarification: lime
        dosage optimization in a Brazilian sugar mill"
Resumen: "A multilayer perceptron trained on 24 months of
        DCS data predicts clarified juice pH ... MAE=0.04
        pH units. Reduces lime overconsumption by 18%."
Decision correcta: INCLUIR Confianza: 97

EJEMPLO 2 - INCLUIR (sintetico: LSTM + soft sensor)
Titulo: "LSTM-based soft sensor for online pH estimation in
        sugar cane juice purification without physical pH
        probe"
Resumen: "An LSTM model estimates juice pH from conductivity,
        temperature, turbidity, Brix and lime flow ...
        R2=0.96, RMSE=0.05 ..."
Decision correcta: INCLUIR Confianza: 96

EJEMPLO 3 - INCLUIR (FUGA: reproduce un estudio incluido)
Titulo: "Optimization based on pattern search algorithm
        applied to pH non-linear control: Application to
        alkalinization process of sugar juice"
Resumen: "A Takagi-Sugeno fuzzy inference model combined with
        a non-linear model predictive controller (NMPC)
        tuned via pattern search optimization (PSM) controls
        pH in the alkalinization of sugar juice ..."
Keywords: pH control; alkalinization; sugar juice; NMPC;
        fuzzy; pattern search; nonlinear
Decision correcta: INCLUIR Confianza: 95

EJEMPLO 4 - EXCLUIR (sintetico: pH en bioetanol de cana)
Titulo: "Machine learning control of fermentation pH for
        bioethanol production from sugarcane bagasse"
Decision correcta: EXCLUIR Confianza: 96
```

```
42
43 EJEMPLO 5 - EXCLUIR (sintetico: pH en cristalizacion)
44 Titulo: "Neural network prediction of massecuite pH and
45         crystal size in vacuum pan"
46 Decision correcta: EXCLUIR Confianza: 91
47
48 EJEMPLO 6 - EXCLUIR (sintetico: aguas residuales)
49 Titulo: "Deep learning for pH prediction in sugar factory
50         wastewater treatment"
51 Decision correcta: EXCLUIR Confianza: 95
52
53 === FIN DE EJEMPLOS ===
54
55 INCLUIR si el articulo cumple TODOS:
56   A) Aplica tecnica de ML/IA (machine learning, redes
57      neuronales, soft sensors, reinforcement learning, MPC,
58      LSTM, CNN, fuzzy logic, gemelos digitales, etc.).
59   B) La aplicacion es CONTROL, PREDICCION, ESTIMACION,
60      MONITOREO u OPTIMIZACION del pH (o acidez, alcalinidad,
61      dosis de cal, dosis de SO2) mediante ML/IA.
62   C) El proceso objetivo PRINCIPAL es la INDUSTRIA AZUCARERA:
63      clarificacion, encalado, defecacion, sulfitacion,
64      carbonatacion o purificacion del jugo de cana o remolacha.
65
66 EXCLUIR si se cumple CUALQUIERA:
67   X1) pH en procesos NO azucareros. X2) pH en suelo, agua
68   subterranea, rios o ambiente. X3) Procesos azucareros
69   distintos a clarificacion/encalado/sulfitacion. X4)
70   Contexto multi-industria alimentaria. X5) pH solo como
71   variable de entrada. X6) Tejidos biologicos o farmacia.
72   X7) Efluentes de la fabrica azucarera. X8) Bioetanol o
73   biocombustibles de cana.
74
75 Responde UNICAMENTE con este JSON exacto:
76 {"decision": "INCLUIR" o "EXCLUIR",
```

```
 "confianza": numero entre 0 y 100,
 "justificacion": "texto conciso, maximo 2 oraciones"}

=== ARTICULO A EVALUAR ===
Titulo: {titulo} Resumen: {resumen} Palabras clave: {keywords}
```

Listing 4: *Prompt* de producción (seis ejemplos sintéticos) para clasificación INCLUIR/EXCLUIR. El Ejemplo 3 contiene la fuga descrita en el texto.

Parámetros de ejecución y reproducibilidad. Modelo `llama3:latest` (Llama 3 de 8B parámetros, cuantización Q4_0) servido localmente con Ollama; resumen SHA-256 del modelo: `365c0bd3c000a25d28ddbf732fe1c6add414de7275464c4e4d1c3b5fcb5d8ad1` (fecha de modificación local: 23 de marzo de 2026, anterior a la corrida de producción); versión del servidor en la re-ejecución: 0.24.0; temperatura $T = 0$; no se fijó semilla. Umbral de derivación: confianza < 55 % (tratado como EXCLUIR). En la corrida de producción sobre los 230 registros, 201 se resolvieron por el filtro léxico local sin invocar al modelo (nivel `LOCAL`), 28 obtuvieron una decisión de alta confianza (nivel `AUTO`, 92–98 %; 2 INCLUIR y 26 EXCLUIR) y 1 cayó bajo el umbral (nivel `INCIERTO`; una entrada de actas mal etiquetada).

Análisis de sensibilidad del *prompt*

Los 29 registros que llegaron al modelo se re-procesaron con el mismo modelo, $T = 0$, con (A) el *prompt* original y (B) un *prompt* corregido en el que el Ejemplo 3 se sustituye por un positivo sintético de otra familia metodológica (control neuro-difuso con programación de ganancia). Las 26 decisiones EXCLUIR restantes no cambiaron. La Tabla B1 resume los registros con decisión relevante.

Tabla B1

Decisión del modelo por registro bajo tres ejecuciones (producción; re-ejecución con prompt original A; re-ejecución con prompt sin fuga B). Entre paréntesis, confianza autoinformada.

Registro	Humano	Producción	A	B
Palacio-Morales et al., 2021	INCLUIR	INCLUIR (95)	INCLUIR (95)	INCLUIR (98)
Murugesan et al., 2020	INCLUIR	INCLUIR (98)	INCLUIR (98)	INCLUIR (98)
Clarificación de jugo con H_2O_2 y redes neuronales (2017)	EXCLUIR	EXCLUIR (92)	INCLUIR (98)	INCLUIR (98)
Otros 26 registros	EXCLUIR	EXCLUIR	EXCLUIR	EXCLUIR

Nota. Concordancia con la decisión humana final: producción 230/230; A y B 229/230. La fuga no determinó la clasificación del estudio de Palacio-Morales et al., 2021, pero la decisión sobre el registro de H_2O_2 cambia entre corridas con $T = 0$, de modo que el chequeo no es reproducible.

Appendix C. Herramienta de evaluación del riesgo de sesgo

Se diseñó una herramienta *ad hoc* de cinco dominios, adaptada de los principios generales de evaluación del riesgo de sesgo en estudios primarios (representatividad de los datos, separación entrenamiento/ validación, completitud de las métricas, línea base y nivel de validación) al contexto de AA y control avanzado en procesos industriales, para el cual no existe una herramienta estandarizada. Su aplicación es opcional en PRISMA-ScR y no se usa para ponderar resultados. La Tabla C1 define los dominios y la Tabla C2 los aplica a los dos estudios incluidos, a partir del **texto completo**.

Tabla C1

Dominios de la herramienta de evaluación del riesgo de sesgo.

Dominio	Pregunta guía	Escala
D1 — Representatividad	¿Los datos usados para identificar/entrenar el modelo provienen del proceso industrial real, de un banco de pruebas, o exclusivamente de simulación?	Industrial > banco de pruebas > simulación
D2 — Separación de datos	¿Se declara una separación explícita entre los datos usados para ajustar el modelo/controlador y los usados para validarlo (p. ej., *train/test split*, validación cruzada)?	Declarada y adecuada / declarada pero limitada / no declarada
D3 — Completitud de métricas	¿Se reportan métricas cuantitativas de desempeño del control de pH (p. ej., error de seguimiento, *overshoot*, tiempo de establecimiento) con suficiente detalle para ser reproducidas?	≥ 2 métricas cuantitativas / 1 métrica o solo cualitativa / ninguna
D4 — Comparación con línea base	¿El desempeño del método propuesto se compara cuantitativamente contra un controlador o algoritmo de referencia (p. ej., PID, PI, u otra metaheurística)?	Comparación cuantitativa explícita / comparación solo cualitativa / sin comparación
D5 — Nivel de validación alcanzado	¿En qué entorno se validó el controlador o modelo resultante (*Technology Readiness Level* aproximado, escala NASA NPR 7123.1B)?	Planta industrial (TRL ≥ 7) / planta piloto (TRL 5–6) / simulación (TRL ≤ 4)

Nota. El riesgo global de cada estudio se calificó de forma cualitativa como *Bajo*, *Moderado* o *Moderado–Alto* según el número de dominios en su categoría más favorable, sin un algoritmo de puntuación numérica formal, dado el tamaño reducido de la muestra de estudios evaluados ($n = 2$) y el carácter exploratorio de esta revisión de alcance.

Tabla C2

Aplicación de la herramienta de riesgo de sesgo a los dos estudios incluidos (texto completo).

Estudio	D1	D2	D3	D4	D5
Palacio-Morales et al., 2021	Simulación (modelo genérico de neutralización)	No declarada	≥ 2 métricas (ICET, sobreimpulso, esfuerzo)	Contra otras cinco sintonías de NMPC; sin PID/PI	Simulación (TRL ≈ 3–4)
Murugesan et al., 2020	Datos reales de planta (3000 muestras)	Declarada (70/30 %)	≥ 2 métricas (MSE, tiempos de subida y asentamiento)	Contra GA y PSO; sin PID de planta	Controlador solo en simulación (TRL ≈ 4)

Nota. **Riesgo global:** Palacio-Morales et al., 2021 — *Moderado–Alto*: D1, D2 y D5 son desfavorables (modelo de planta simulado, sin separación de datos declarada, sin planta), D3 es favorable y D4 parcial; sin comparación con un controlador de referencia tipo PID. Murugesan et al., 2020 — *Moderado*: D1, D2 y D3 son favorables y D4 parcial (comparación solo con otras metaheurísticas), pero D5 es desfavorable porque el controlador no se probó en planta y el modelo identificado es lineal de segundo orden. Ambos comparten la ausencia de validación en lazo cerrado en planta, coherente con la prioridad que encabeza la agenda (4.3). Una versión anterior de esta evaluación se basó en los resúmenes y se corrigió tras la lectura del texto completo.

Appendix D. Notas metodológicas sobre la fiabilidad del cribado (κ)

1. Métrica primaria: κ inter-humano

La concordancia entre los Revisores 1 y 2 se calcula sobre los 230 registros (Tabla 2); ambos cribaron el corpus completo, por lo que no hay error de muestreo en la cobertura. Con solo dos casos positivos, sin embargo, un único desacuerdo habría bajado κ de forma drástica (con un desacuerdo sobre un positivo, $\kappa \approx 0.66$), y la ausencia total de desacuerdos produce $\kappa = 1.000$ y PABAK $= 1.000$ sin que ello permita estimar la variabilidad entre revisores. Por eso la métrica se reporta junto con P_0 y los intervalos de Wilson (sensibilidad y precisión: 2/2, IC 95 % 34.2–100 %; P_0: 230/230, IC 95 % 98.4–100 %), y se interpreta como estimación de la fiabilidad del proceso de exclusión, no del acierto sobre los positivos (Byrt et al., 1993; Feinstein & Cicchetti, 1990).

2. Métrica secundaria: concordancia con el *pipeline* automático

Tabla D1

Concordancia del pipeline automático con la decisión humana final sobre los 230 registros Q1–Q4: corrida de producción y re-ejecución (prompts A y B).

	VP	FP	FN	VN	P_0	κ
Producción	2	0	0	228	1.000	1.000
Re-ejecución A y B	2	1	0	227	0.996	0.798

Nota. VP: verdaderos positivos; FP: falsos positivos; FN: falsos negativos; VN: verdaderos negativos. Producción: sensibilidad 100 % (IC 95 % de Wilson $[34.2, 100]$), precisión 100 % ($[34.2, 100]$), $F_1 = 100\,\%$, PABAK = 1.000. Re-ejecución: sensibilidad 100 % ($[34.2, 100]$), precisión 66.7 % ($[20.8, 93.9]$), $F_1 = 80.0\,\%$, PABAK = 0.991.

3. Fragilidad estadística y paradoja del κ

Con dos observaciones positivas, la sensibilidad y la precisión provienen de cocientes 2/2 o 2/3 y sus intervalos de Wilson al 95 % son amplios ($[34.2\,\%, 100\,\%]$ y $[20.8\,\%, 93.9\,\%]$). La diferencia entre $\kappa = 0.798$ y PABAK = 0.991 en la re-ejecución ilustra que κ cae con la prevalencia mientras PABAK no, y que ninguno sustituye a la inspección de la matriz de confusión. Un clasificador que respondiera EXCLUIR siempre alcanzaría $P_0 = 0.991$ y PABAK = 0.983 sin detectar ningún positivo. La inestabilidad $1.000 \rightarrow 0.798$ entre corridas con $T = 0$ confirma que no debe presentarse $\kappa = 1.000$ como resultado definitivo.

4. Requisitos para una validación robusta

(a) Incluir un tercer revisor o estimar la concordancia en un corpus con más positivos, para que κ sea informativo; (b) fijar la versión y el resumen SHA-256 del modelo y una semilla, y repetir varias corridas para estimar la variabilidad; (c) sustituir el Ejemplo 3 por un positivo sintético sin fuga; (d) comparar varios modelos; y (e) repetir la evaluación en un corpus de mayor prevalencia. La reducción teórica de carga manual ($228/230 \approx 99.1\,\%$) es un beneficio potencial, no un ahorro materializado, pues la revisión humana cubrió el 100 % del corpus.

Appendix E. Lista de verificación PRISMA-ScR

Tabla E1

Lista de verificación PRISMA-ScR (Tricco et al., 2018) y ubicación de cada ítem en el manuscrito.

#	Ítem	Ubicación
1	Título	Portada: identifica el diseño como revisión de alcance
2	Resumen estructurado	Resumen (párrafo único con contexto, métodos, resultados y conclusión)
3	Justificación	§1.4; §1.3
4	Objetivos	§1.5 (PICOC y RQ1–RQ3)
5	Protocolo y registro	§2.1 (OSF, registro retrospectivo; desviaciones declaradas)
6	Criterios de elegibilidad	§2.2
7	Fuentes de información	§2.3
8	Estrategia de búsqueda	§2.3; Apéndice A
9	Selección de las fuentes de evidencia	§2.4; §2.5
10	Proceso de extracción de datos	§2.6
11	Elementos de datos	§2.6; Tabla 3
12	Evaluación crítica de las fuentes (opcional)	§2.6; Apéndice C
13	Síntesis de resultados	§2.6; §2.7; §2.8
14	Selección de las fuentes de evidencia (resultados)	§3.1; Figura 3
15	Características de las fuentes	§3.3; §3.4
16	Evaluación crítica dentro de las fuentes	Apéndice C (Tabla C2)
17	Resultados de las fuentes individuales	§3.3; Tabla 3
18	Síntesis de resultados	§3.4–3.6
19	Resumen de la evidencia	§4.1
20	Limitaciones	§4.4
21	Conclusiones	§5
22	Financiamiento	Portada

Appendix F. Evidencia complementaria y auditorías de sensibilidad

F.1 Trabajos *in-domain* excluidos por criterios formales

La Tabla F1 lista los 11 trabajos identificados con la verificación léxica de 2.7 que combinan pH, proceso azucarero y control avanzado o AA, y que no pasaron al cribado por tipo de documento (8) o por carecer de cuartil SJR (3). Se describen a partir de sus resúmenes y no forman parte del corpus incluido.

Tabla F1

Evidencia in-domain excluida por criterios formales (descripción según resumen).

Referencia	Proceso y método	Validación declarada	Fuente	Motivo
S. Sunori et al., 2016	Neutralización de pH del clarificador; controladores ZN, IMC y LQG optimizados con GA	Simulación	*Oriental J. Chem.*	Sin cuartil SJR
Wang, 2017	Clarificación en refinería; PID adaptativo difuso con diseño de *hardware* y *software*	Resultados experimentales (escala no precisada)	*Acta Technica CSAV*	Sin cuartil SJR
Rajalakshmi et al., 2022	Clarificador; identificación y sintonía con STA, GA y PSO	No especificada	*Intell. Autom. Soft Comput.*	Sin cuartil SJR ("-")
S. K. Sunori et al., 2017	Neutralizador de pH; reducción de orden de un modelo FOPDT; ZN, IMC y GA-IMC	Simulación	Acta (CICN)	Tipo documento
Rajalakshmi et al., 2018	Clarificador; SVR con PSO y firefly para modelado	No especificada ("problemas industriales en tiempo real")	Acta (NPEC)	Tipo documento
S. K. Sunori et al., 2020	Neutralización de pH; modelo neuro-difuso ANFIS	Simulación (MATLAB)	Acta (ICACCM)	Tipo documento
Jethi et al., 2021	Neutralización de pH; MPC frente a PID	Simulación (MATLAB)	Acta (GCAT)	Tipo documento
Kalavathi Devi et al., 2021	Regulación de pH con PID-IMC; banco con celda de carga y sensor de pH	Prototipo y simulación	Acta (ICECCT)	Tipo documento
S. K. Sunori, Joshi et al., 2022	Control de pH en refinería; H_∞ y MPC sobre función de transferencia	Simulación (MATLAB)	Acta (ICSSIT)	Tipo documento
S. K. Sunori, Bhakuni Negi et al., 2022	Control de pH en refinería; ANFIS frente a PI	Simulación (MATLAB)	Acta (ICACCS)	Tipo documento
S. K. Sunori, Negi et al., 2022	Control de pH en ingenio; PI optimizado con GA y SA	Simulación (MATLAB)	Serie *LNNS*	Tipo documento

Un registro limítrofe, Vlasenko et al., 2023, modela con una red neuronal la eficiencia de la defecosaturación de jugo de remolacha usando el pH como entrada; no se contabiliza por el criterio de exclusión (e).

F.2 Familias de expresiones regulares de la verificación léxica

Sobre título, resumen y palabras clave en minúsculas: *pH* (`\bph\b`, neutralización, alcalinización, encalado, defecación, sulfitación, carbonatación); *proceso azucarero* (*sugar mill/factory/industry/process*, *juice clarification*, *clarifier*, *raw/mixed/cane/sugar juice*, *sugar beet*, *sugar refinery*, *liming*); sensor virtual (*soft/virtual/inferential sensor*); MPC (*model predictive control*, *NMPC*, *MPC*); refuerzo (*reinforcement learning*, *DDPG*, *Q-learning*, *actor-critic*); PID (*PID*, *proportional-integral*); difuso (*fuzzy*, *neuro-fuzzy*, *ANFIS*, *Takagi*); metaheurísticas (*genetic algorithm*, *particle swarm*, *differential evolution*, *pattern search*, *state transition algorithm*, *metaheuristic*); adaptativo (*adaptive control*, *gain scheduling*, *self-tuning*); AA general (*neural network*, *machine learning*, *deep learning*, *random forest*, *support vector*, *LSTM*); gemelo digital (*digital twin*).

F.3 Auditoría del filtro léxico local

De los 201 registros resueltos por el filtro L0–L2, 26 combinaban vocabulario de pH y de proceso azucarero según un criterio más laxo (sin reglas L0 ni requisito de AA), y 11 de ellos incluían además vocabulario de control o estimación. Su lectura por título y resumen mostró que tratan conservación, pardeamiento enzimático, pasteurización, cavitación o blanqueo de jugos y bebidas, tratamiento de melazas y residuos, filtración con membranas, dosificación de coagulantes en agua potable o temas no relacionados (salud, fruta), y **ninguno** aborda la regulación del pH de la clarificación o el encalado. La lista completa (título, año, DOI y resumen) está en `03_filtered_data/13.auditoria_filtro_local.csv`.